

R

Sergio Pedro R Oliveira

25 maio 2023

Contents

1	Objetivo	3
2	Livro de referência	3
3	Cap 1 - Instalação do R e Rstudio	4
4	Cap 2 - Pacote base e funções estatísticas básicas	5
4.1	Operações matemáticas básicas	5
4.2	Vetor	5
4.3	Tabela de dados (data.frame) e matrizes	6
4.4	Acessando valores em posições especificadas dos objetos - vetor , matriz e data.frame . . .	7
4.5	Visualizando dados	8
4.6	Funções estatísticas básicas	10
5	Cap 3 - Principais pacotes	12
5.1	Instalação de pacotes	12
5.2	Pacotes	12
5.3	Carregamento de pacotes	13
5.4	Obter ajuda (informações) sobre pacotes	13
6	Sites para uso Remote do R	14
7	Cap 4 - R Markdown	15
7.1	Preâmbulo	15
7.2	<i>Chunks</i> (códigos embutidos)	18
7.3	Titulos e subtítulos	21
7.4	Pular linha	21
7.5	Listas	22
7.6	Notas de rodapé (cliqueáveis)	23
7.7	Inserir tabelas	24
7.8	Hiperlinks e imagens	34
7.9	Fórmulas LaTeX	35
7.10	Letras gregas	40
7.11	Formatação (Fontes)	41
7.12	Abas	41

8	Cap 5 - Pacotes do Tidyverse e identificando/mudando tipos de variáveis	42
8.1	Identificando/mudando tipos de variáveis	42
8.2	Pacotes do Tidyverse	43
8.3	Leitura de dados (readr)	44
8.4	tibble	50
8.5	Operador pipe	52
8.6	Manipulando dados com o dplyr	53
8.7	Organizando dados com o tidyr	64
9	Cap 6 - Pacote data.table	69
9.1	Teoria	69
9.2	Estrutura	69
9.3	Transformando data.frame em data.table	69
9.4	data.table	71
10	Cap 7 - Gráficos pacote básico e pacote ggplot2	75
10.1	Gráficos com o pacote básico	75
10.2	Pacote ggplot2	101
11	Andamento dos Estudos	107
11.1	Assunto em andamento:	107
	Referências	108

1 Objetivo

Estudo dirigido de linguagem R.

2 Livro de referência

Utilizando a Linguagem R.

Editora: ALTA BOOKS EDITORA

3 Cap 1 - Instalação do R e Rstudio

- Download da linguagem R:
<https://www.r-project.org/>
- Download Rstudio IDE:
<https://posit.co/downloads/>

4 Cap 2 - Pacote base e funções estatísticas básicas

4.1 Operações matemáticas básicas

Table 1: Operações básicas do R

Nome da operação	Operação	Resultado
Adição	5+4	9
Subtração	6-2	4
Multiplicação	7*3	21
Divisão	45/9	5
Potência	2^2	4
Raiz	sqrt(121)	11
Exponencial	exp(0)	1
Log na base e	log(1)	0
Log na base 10	log10(1)	0
Log na base 2	log2(4)	2
Log na base 3 ou qualquer outra	log(9,3)	2

4.2 Vetor

- Para criar um vetor usamos a função `c()`.
- Os argumentos são separados por vírgula dentro do parênteses.
- strings devem estar entre aspas duplas.
Ex.: `c("um","sete","nove")`
- Vetores são compostos de elementos todos do mesmo tipo.
- Armazenando vetores em um objeto:
Ex.: `obj_qualquer <- c(1,2,3)`

4.3 Tabela de dados (`data.frame`) e matrizes

4.3.1 `data.frame`

- Uma tabela onde cada coluna é um vetor.
- Como cada coluna é um vetor, cada coluna pode ser de um tipo diferente.
Ex.: `nome_data.frame <- data.frame(vetor_1, vetor_2)`
- Acrescentando uma nova coluna ao `data.frame`.
Ex.: `nome_data.frame <- data.frame(nome_data.frame, vetor_3)`
- Para visualizar um **`data.frame`** podemos usar a função **`View()`**.
Ex.: `View(nome_data.frame)`

4.3.2 Matrizes

- A diferença entre **matrizes** e **`data.frames`**, é que no caso das matrizes todas as colunas e linhas devem ser do mesmo tipo. Enquanto nos **`data.frames`** as colunas podem ser de tipos diferentes.
- Para adicionar uma coluna numa matriz, usamos a função `cbind()`.
Ex.: `nome_matriz <- cbind(vetor_1, vetor_2, ...)`
- Para adicionar uma linha numa matriz, usamos a função `rbind()`.
Ex.: `nome_matriz <- rbind(vetor_3, vetor_4, ...)`
- Quando inserimos dados (vetor) de naturezas diferentes (tipos) numa matriz, ela converte todos os dados para um único tipo. A princípio *string* (*chr*).

4.4 Acessando valores em posições especificadas dos objetos - vetor, matriz e data.frame

4.4.1 Caso vetor e matriz

- Podemos acessar os valores do objeto tipo **vetor** e **matriz**, informando a posição entre colchetes [].
- Para os **vetores** precisamos apenas informar a posição. A contagem da posição começa a partir do 1.
Ex.:
`vetor <- c(5,18,89)`
`vetor[1]`
- Para as **matrizes**, é necessário informar a posição [*linha*, *coluna*]. A contagem da posição começa a partir do 1.
Ex.: `Mc[1,2]`
- Para acessar todos os valores de uma *linha* da **matriz**, podemos determinar a *linha* e deixar a *coluna* em branco.
Ex.: `Mc[1,]`
- Para acessar todos os valores de uma *coluna* da **matriz**, podemos determinar a *coluna* e deixar a *linha* em branco.
Ex.: `Mc[,2]`

4.4.2 Caso data.frame

- No caso do **data.frame** podemos acessar os valores das colunas informando, “nome do **data.frame**” “\$” “nome da coluna”.
Sintaxe:
`nome_dataframe$nome_coluna`
- O **data.frame** também aceita as mesmas formas de acessar posições que as **matrizes**.

4.5 Visualizando dados

4.5.1 View() - visualização de dados

- Podemos visualizar dados de duas formas:
 - Escrevendo o nome da variável
O valor dela será impressa na tela.
 - Atraves da função **View()**
Ao chamar a função View() e colocar dentro a variavel que queremos ver, será exibido uma nova janela com o valor da variável numa tabela.

4.5.2 str() - estrutura de objetos

- A função “**str()**” retorna a estrutura do objeto do argumento.
- Retorna diversos dados, entre eles:
 - A classe do objeto.
 - Tamanho do objeto.
 - A lista, ou vetor, dos campos com o tipo e tamanho.
- Sintaxe:
`str(argumento)`

4.5.3 summary() - resumo de variáveis

- A função **summary()** retorna o resumo de variaveis.
- O retorno depende do argumento (se for um vetor, uma lista, um data.frame).
- O retorno para uma matriz ou **data.frame**, vai ser os metodos aplicados a cada campo/coluna.
- O retorno da função, no geral, retorna diversos metodos aplicados aos dados, tais como:
 - valor mínimo
 - 1º quantil
 - valor da mediana
 - valor da media
 - 3º quantil
 - valor máximo
- Sintaxe:
`summary(nome_variavel)`

4.5.4 `class()` - classe de objetos

- A função “**class()**” retorna a que classe do objeto do argumento pertence.
- Basicamente diz se o objeto é numerico, string, vetor, lista, data.frame, matriz, ...
- Sintaxe:
`class(argumento)`

4.6 Funções estatísticas básicas

Função	Descrição
<code>apply(D,i,f)</code>	Retorna os valores resultantes da aplicação da função <code>f</code> ao objeto <code>D</code> , linhas <code>i=1</code> , ou colunas <code>i=2</code> .
<code>c(valor1, valor2, valor3)</code>	Concatena uma sequência de valores seja numérico ou de caracteres. Neste último caso os valores devem estar entre aspas.
<code>cbind(x1, x2, ..., xn)</code>	Cria uma matriz com <code>n</code> colunas formada pelos vetores <code>x1, x2, ..., xn</code> .
<code>ceiling(x)</code>	Retorna o menor inteiro maior ou igual ao valor <code>x</code> .
<code>cor(x,y)</code>	Calcula o coeficiente de correlação.
<code>cumsum(x)</code>	Retorna um vetor com valores acumulados em soma sobre os elementos de <code>x</code> .
<code>cumprod(x)</code>	Retorna um vetor com valores acumulados em produto sobre os elementos de <code>x</code> .
<code>cummin(x)</code>	Retorna um vetor com valores acumulados em mínimo sobre os elementos de <code>x</code> .
<code>cummax(x)</code>	Retorna um vetor com valores acumulados em máximo sobre os elementos de <code>x</code> .
<code>data.frame(x1, x2, ..., xn)</code>	Cria um dataframe com os valores <code>x1, x2, ..., xn</code> .
<code>det(M)</code>	Calcula o determinante da matriz quadrada <code>M</code> .
<code>dim(M)</code>	Retorna as dimensões do objeto <code>M</code> .
<code>diff(x)</code>	Retorna um vetor com a diferença entre os valores de <code>x</code> .
<code>eigen(M)</code>	Retorna os autovalores e os autovetores da matriz quadrada <code>M</code> .
<code>floor(x)</code>	Retorna o maior inteiro menor ou igual a <code>x</code> .
<code>identical(x,y)</code>	Verifica se os vetores são idênticos.
<code>intersect(x,y)</code>	Realiza a interseção de dois conjuntos.
<code>head(D)</code>	Mostra o cabeçalho do objeto <code>D</code> .
<code>length(x)</code>	Calcula o comprimento do vetor <code>x</code> .
<code>mean(x)</code>	Calcula a média do vetor <code>x</code> .
<code>median(x)</code>	Calcula a mediana do vetor <code>x</code> .
<code>min(x)</code>	Calcula o mínimo de <code>x</code> .
<code>max(x)</code>	Calcula o máximo de <code>x</code> .
<code>ncol(M)</code>	Retorna o número de colunas da matriz <code>M</code> .
<code>nrow(M)</code>	Retorna o número de linhas da matriz <code>M</code> .
<code>polyroot(x)</code>	Encontra as raízes do polinômio de ordem <code>n</code> cujos coeficientes são representados no vetor <code>x</code> em ordem decrescente.
<code>prod(x)</code>	Multiplica os valores de <code>x</code> .
<code>quantile(x,k)</code>	Calcula o percentil de ordem $0 \leq x \leq 1$ dos valores de <code>x</code> .
<code>Re(x)</code>	Retorna a parte real de um vetor <code>x</code> .
<code>rep(x,k)</code>	Cria um vetor repetindo a sequência <code>x</code> <code>k</code> vezes.
<code>round(x,k)</code>	Arredonda o valor <code>x</code> com <code>k</code> casas decimais.
<code>sd(x)</code>	Calcula o desvio-padrão do vetor <code>x</code> .
<code>seq(i,j,k)</code>	Cria uma sequência de <code>i</code> até <code>j</code> com tamanho de passo <code>k</code> .
<code>setdiff(x,y)</code>	Retorna um vetor contendo os elementos do conjunto diferença entre <code>x</code> e <code>y</code> .
<code>setequal(x,y)</code>	Verifica se os elementos dos vetores <code>x</code> e <code>y</code> são iguais, independentemente da frequência em que aparecem no vetor.
<code>solve(A,b)</code>	Resolve $Ax=b$, retornando <code>x</code> .
<code>sort(x)</code>	Ordena os valores de vetor <code>x</code> em ordem crescente.
<code>sort(x, decreasing = T)</code>	Ordena os valores de <code>x</code> em ordem decrescente.

Função	Descrição
<code>str(D)</code>	Retorna a estrutura do objeto D.
<code>sum(x)</code>	Soma os valores de x.
<code>union(x,y)</code>	Retorna os elementos da união entre x e y.
<code>var(x)</code>	Calcula a variância do vetor x.
<code>var(x,y)</code>	Calcula a covariância entre x e y.
<code>View(D)</code>	Mostra o dataframe em janela separada.

5 Cap 3 - Principais pacotes

5.1 Instalação de pacotes

- sintaxe de instalação:
`install.packages("nome do pacote")`
- sintaxe de variáveis instalações simultaneas:
`install.packages(c("nome do pacote", "nome do pacote", ...), dependencies = TRUE)`

5.2 Pacotes

1. Principais pacotes:

- **stringr**
Pacote para trabalhar com strings (texto).
- **Rmarkdown**
Produção de relatórios (html, pdf, doc, md).
- **knitr**
Interpretação e compilação do documento rmd.
- **data.table**
Exploração de data.frames.
- **janitor**
Limpeza de dados.
- **DescTools**
Análise descritiva de dados.
- **tidyverse**
conjunto de pacotes.
 - **readr**
Importação e leitura de arquivos de dados.
 - **tibble**
estruturação de data.frame.
 - **dplyr**
Manipulação de data.frame.
 - **tidyr**
Organização de data.frame.

- **ggplot2**
Visualização de dados, produção de gráficos.
 - **purrr**
Manipulação de vetores e listas.
 - **foreign**
Leitura e gravação de dados armazenados por algumas versões de “Epi Info”, “Octave”, “Minitab”, “S”, “SAS”, “SPSS”, “Stata”, “Systat”, “Weka” e para leitura e gravação de alguns “dBase” arquivos.
 - **devtools**
Para instalar pacotes que não estejam no **CRAN**.
2. Pacotes auxiliares ao pacote **ggplot2**:
- **ggthemes**
 - **grid**

5.3 Carregamento de pacotes

- Para poder utilizar o conjunto de funções de um determinado pacote, não basta apenas instalar o pacote, é preciso carregá-lo no script.
- As principais formas de carregar um pacote no script é através dos comandos *library()* e *require()*.
library(*nome_pacote*)
require(*nome_pacote*)
- Outra possibilidade, é ao usar um função especificar a qual pacote ela pertence.
nome_pacote::função.

5.4 Obter ajuda (informações) sobre pacotes

Duas formas de se conseguir informações sobre determinado pacote é através dos comandos:

1. `package?nome_pacote`
2. `help(package = "nome_pacote")`

6 Sites para uso Remote do R

- Alguns sites que possibilitam utilizar o R básico, sem que seja necessário instalá-lo no computador.
- Uma ótima saída quando necessário utilizar em algum computador público (lan houses, hotéis, laboratórios, ...)

1. <http://rstudio.cloud/>
2. <http://jupyter.org/try>
3. http://www.tutorialspoint.com/execute_r_online.php
4. http://github.com/datacamp/datacamp_light
5. <http://rdr.io/snippets>
6. <http://www.jdoodle.com/execute-r-online>
7. http://rextester.com/l/r_online_compiler
8. <http://rnotebook.io>

7 Cap 4 - R Markdown

7.1 Preâmbulo

7.1.1 Título

title: “Título desejado”

7.1.2 Autor

- Para inserir um autor:
author: “Nome do autor”
- Para inserir varios autores:
author:

– autor_1^[instituto]

– autor_2^[instituto]

7.1.3 Data

- O comando “*date*:”, adiciona uma data ao documento.
- Podemos adicionar uma data qualquer para o documento no formato “dd/mm/aaaa”.
date: “dd/mm/aaaa”
- Outra possibilidade é usar uma função dentro de um *chunk* “r Sys.Date()”, para adicionar a data atual do sistema (modelo inglês).
date: “r Sys.Date()”
- Outra opção é usar o a função dentro de um *chunk* “r format(Sys.time(), ‘%d %B %Y’)”. A data será gerada no modelo: 02 agosto 2004.
date: “r format(Sys.time(), ‘%d %B %Y’)”
Obs.: *chunk* deve ser colocado entre acentos graves.

7.1.4 Tipo do Documento (*output*)

- *output*: o tipo de saída, podem ser:

– Documentos:

* *pdf_document*

* *md_document*

* *html_document*

* *word_document*

- * *odt_document*
- * *rtf_document*
- Apresentação:
 - * *powerpoint_presentation*
 - * *ioslides_presentation*
 - * *beamer_presentation*
- mais:
 - * *flexdashboard::flex_dashboard*
 - * *github_document*

7.1.5 Sumário

- Para inserir o sumário no documento, basta colocar o comando “*doc: yes*” indentado dentro do tipo de saída.
- O comando **number_sections: true** adiciona numeração aos capítulos do sumário.

7.1.6 Formatação desejada

Para determinar a formatação desejada, basta salvar um arquivo com o nome *estilo.docx*, que contenha a formatação e referenciar o arquivo, indentado dentro do tipo de arquivo, através do comando “*reference_docx: caminho/.../estilo.docx*”.

7.1.7 Abstract

Abstract: “Texto de abstract”.

7.1.8 Bibliografia

- Ter um arquivo *.bib com as referencias.
- Adicionar o arquivo *.bib no preâmbulo do **R Markdown**, através do comando:
bibliography: caminho/arquivo.bib
- Um arquivo *.csl com o estilo da citação.
Este arquivo pode ser obtido no site:
<https://www.zotero.org/styles>
Pesquisar por: “abnt”
Opção: “Instituto de Pesquisa Econômica Aplicada - ABNT (Português - Brasil)”
- Adicionar o arquivo *.csl no preâmbulo do R Markdown, através do comando:
csl: caminho/arquivo.csl

- É necessário criar um capítulo no final para as referências. A bibliografia vai ser alocada no final do documento, logo neste último capítulo. A bibliografia é sempre inserida ao final do documento.
- Por fim, para aparecer as referências elas precisam ser citadas no texto.
As principais formas de citar uma referência num texto de **R Markdown** é:

- Uma citação:

Exemplo do comando: `[@ chave_da_referencia]`

Exemplo de como fica no arquivo final: (Alcoforado, 2021).

- Mais de uma citação ao mesmo tempo:

Exemplo do comando: `[@ chave_da_referencia_1, @ chave_da_referencia_2]`

7.2 *Chunks* (códigos embutidos)

7.2.1 Códigos embutidos no texto

- Podemos embutir códigos ao longo do texto.
- Para inserir um código que será rodado no meio do texto, usamos um sinais de crase para abrir, definimos a linguagem (normalmente `r`), o comando que desejamos e um sinal de crase para fechar o código.
Este é um código embutido
- Para rodar pequenos comandos no meio do texto códigos embutidos é uma ótima opção.
- Exemplo:
O resultado do comando `1:3` é criar uma sequencia com os valores `1:3`. A soma destes valores é `sum(1:3)`.
O resultado do comando `1:3` é criar uma sequencia com os valores 1, 2, 3. A soma destes valores é 6.

7.2.2 *Chunk*

- Códigos em R, ou em outras linguagens, podem ser inseridos nos documentos através de *chunks*.
- *Chunks* são blocos de programação.
- A principal forma de inserir *chunks* é:
- Três sinais de acento grave (crases) para abrir o *chunk*.
- Na primeira linha, definir a linguagem do bloco de programação:
 - **R**
 - **Python**
 - **Julia**
 - **C++**
 - **SQL**
 - ...
- Para dar um nome ao *chunk*, após definir a linguagem de programação basta colocar o nome do *chunk*. Nomear o *chunk* facilita determinar sua função dentro do relatório/documento.
- Ainda na primeira linha, considerações sobre o bloco de programação (*chunk options*):
 - *include*
Mostra (*true*), ou não (*false*), o código e os resultados no arquivo finalizado. O R Markdown ainda executa o código e o resultado dele ainda pode ser usado em outro bloco de programação.
`include = false | true`
 - *echo*
Impede (*false*), ou não (*true*), que o código apareça, não afeta o resultado.

echo = *false* | *true*

– *results*

“*hide*” mostra o código e omite o resultado.

results = “*hide*”

– *message*

Imprede (*false*), ou não (*true*), que mensagens geradas por código apareçam no arquivo finalizado.

message = *false* | *true*

– *warning*

Imprede (*false*), ou não (*true*), que avisos gerados pelo código apareçam no final.

warning = *false* | *true*

– *fig.cap*

Adiciona uma legenda aos resultados gráficos.

fig.cap = “...”

- Bloco de programação, escrito na linguagem definida.
- Três sinais de acento grave (crases) para fechar o *chunk*.
- Outras formas de inserir *chunks* é através do botão *Insert*, na área superior da tela do script, do **RStudio**.
- Observação:
mensagem e *warning* igual a *false* é muito utilizado quando se carrega bibliotecas (**library**) no *chunk*, evita que as mensagens do carregamento apareçam.

7.2.3 Configurando imagens e tabelas dentro do *chunk*

- Os comandos de configuração de imagem no *chunk* são inseridos no cabeçalho do *chunk*.
- Principais comando de configuração de imagens com *chunk*:

– **fig.width** =

Largura da figura em cm na janela gráfica.

– **fig.height** =

Altura da figura em cm na janela gráfica.

– **fig.align** =

Alinha a figura no arquivo final (“left”, “right” ou “center”).

– **fig.cap** = ” “

Texto para legenda.

– **dpi** =

Valor referente a qualidade da imagem, padrão é 72.

– **out.width** ou **out.height** =

Porcentagem do tamanho original da imagem.

7.2.4 Global *Chunk*

- Para definir as opções globais que se aplicam a cada parte do seu arquivo, chame `knitr::opts_chunk$set` em uma parte do código.
- O **knitr** tratará cada opção que você passar para `knitr::opts_chunk$set` como um padrão global que pode ser substituído em cabeçalhos de blocos individuais.

7.3 Titulos e subtitulos

- Ao utilizar o comando `#` e em sequencia um texto, geramos um titulo.
`# Titulo`
- A cada `#` que adicionamos, diminuimos uma camada de subtitulos.
`## Subtitulo`

7.4 Pular linha

- Para que duas frases fiquem em linhas separadas, dê dois espaços entre elas.
- Os dois espaços funcionam também para deixar uma linha em branco.
- Outra forma é adicinal `“\”`, tem o mesmo efeito.

7.5 Listas

7.5.1 Listas numeradas

- Basta inserir o número seguido de ponto e espaço.
 1. Tópico da lista numerada
- A ordem das principais camadas de lista numeradas são:
 - Número
 1. Primeira camada
 - Algarismos romanos
 - i) Segunda camada
 - Letra
 - A. Terceira camada
- Para inserir uma lista dentro de uma outra lista, é necessário indentar os tópicos.

7.5.2 Listas não numeradas

- Os principais símbolos (na ordem de utilização) da lista não numerada:
 - Asterisco(*)
 - Mais(+)
 - Traço(-)
- Para inserir uma lista dentro de uma outra lista, é necessário indentar os tópicos.

7.6 Notas de rodapé (clicáveis)

- Há duas opções para criar uma nota de rodapé:
 1. Escrever ao final do texto `[^1]` e então (pode ser logo abaixo, ou depois) escrever a nota de rodapé:
“Essa informação não é um consenso `[^1]`”
`[^1]: Esta é uma nota de rodapé.`
 2. Colocar a informação da nota de rodapé no meio do texto, e o R numerará automaticamente:
“Essa informação não é um consenso `^[Esta é uma nota de rodapé]`”
- Observação:
A informação da nota de rodapé deve estar separado do texto por uma linha, no primeiro caso, ou contida na nota no link clicável, como no segundo caso.
- Exemplo:
O RMarkdown é uma ferramenta excelente para documentar seus códigos e apresentar os resultados. As muitas funcionalidades dele são descritas detalhadamente no livro R Markdown: The Definitive Guide ¹.

¹R Markdown: The Definitive Guide. Yihui Xie, J. J. Allaire, Garrett G. Grolemund. Disponível em: <https://bookdown.org/yihui/rmarkdown/>

7.7 Inserir tabelas

7.7.1 Formato de tabela padrão

- A tabela mais simples é através do padrão:
 - Primeira linha:
Cabecalho das colunas, separado por barra vertical(|).
 - Segunda linha:
 - * Tracejados (pelo menos 3), para representar cada coluna, com dois pontos onde se espera que o texto esteja alinhado:
 - Dois pontos no início do tracejado para representar alinhamento do texto a esquerda.
 - Dois pontos no início e no fim do tracejado para representar alinhamento centralizado do texto.
 - Dois pontos no final do tracejado para representar alinhamento do texto a direita.
 - * Cada coluna separada por barra vertical.
 - Terceira linha em diante:
Cada dado de linha em uma linha, com os dados de cada coluna separado por barras verticais.

7.7.2 Criador de tabelas online para R Markdown

Site que ajuda a construir tabelas para **R Markdown**:

https://tablesgenerator.com/markdown_tables

7.7.3 Tabelas provenientes de banco de dados

7.7.3.1 Mostrar todos os dados Dentro do *chunk* chamar a variável que contém um **dataframe**, para imprimir ela na tela.

7.7.3.2 Mostrar apenas os primeiros dados

- Dentro do *chunk* chamar a variável que contém um **dataframe**, e usar a função **head()** que mostra as 5 primeiras linhas. Podemos adicionar o parâmetro de quantidade de linhas desejamos apresentar.
- Exemplo:
head(var_dataframe, n_linha)

7.7.3.3 Bibliotecas para criação de Tabelas

7.7.3.3.1 kable

- Dentro do *chunk*, podemos chamar a biblioteca **knitr**, e usar a função **kable()** onde podemos chamar como argumento a variável **dataframe** (e outras funções).
- A função **kable()**, apresenta uma tabela em formato mais profissional.
- Argumentos do **kable**:

- **format**

Tipos de formatos que a tabela pode ser representada.

```
knitr::kable(head(mtcars[, 1:4]), "pipe")
```

- * pipe

- * simple

- * latex

- * html

- * rst

- **col.names**

O nome das colunas.

Podemos usar o argumento **col.names** para substituir os nomes das colunas por um vetor de novos nomes.

```
knitr::kable(iris, col.names = c('We', 'Need', 'Five', 'Names', 'Here'))
```

- **row.names**

Adiciona nome as linhas.

- **align**

Para alterar o alinhamento das colunas da tabela.

Podemos usar um vetor contendo os valores consistindo dos caracteres **l** (esquerda), **c** (centro) e **r** (direita).

```
kable(..., align = c("l","c",...))
```

ou

```
knitr::kable(iris2, align = "lccrr")
```

- **caption**

Adiciona uma legenda a tabela.

```
knitr::kable(iris2, caption = "An example table caption.")
```

- **digits**

Define o número máximo de casas decimais.

```
knitr::kable(d, digits = 4)
```

```
knitr::kable(d, digits = c(5, 0, 2))
```

- **format.args**

Define o formato me que os números serão apresentados.

* scientific

Se é no formato científico (**true** ou **false**).

```
knitr::kable(d, digits = 3, format.args = list(scientific = FALSE))
```

* big.mark

Como será a separação para números grandes.

```
knitr::kable(d, digits = 3, format.args = list(big.mark = ",", scientific = FALSE))
```

— escape

Ativa (**TRUE**) e desativa (**FALSE**) os caracteres especiais.

```
knitr::kable(d, format = "latex", escape = TRUE)
```

- Exemplo:

```
library(knitr)
kable(head(var_dataframe,10))
```




Figure 1: Exemplo Tabela kable

7.7.3.3.2 kableExtra

- Para mais opções de formatação do `knitr::kable`, temos o pacote `kableExtra`.
- `kableExtra` é um pacote complementar ao `knitr::kable`, por conta disto, é necessário chamar a função `kable` (primeiramente), e concatenar as funções do pacote `kableExtra` pelo operador pipe `%>%`.

```
library(knitr)
library(kableExtra)
kable(iris) %>%
  kable_styling(latex_options = "striped")
```

- Definir o tamanho da fonte:

```
kable(head(iris, 5), booktabs = TRUE) %>%
  kable_styling(font_size = 8)
```

- Estilizar linhas e colunas específicas:

– Funções:

- * **row_spec**
Especifica a linha que vai ser estilizada.
- * **column_spec**
Especifica a coluna que vai ser estilizada.

– Estilizações:

- * negrito (**bold**)
- * italico (**italic**)
- * fundo preto (**background**)
- * fonte branca (**color**)
- * sublinhado (**underline**)
- * espaçamento (**monospace**)
- * ângulo (**angle**)

```
kable(head(iris, 5), align = 'c', booktabs = TRUE) %>%
  row_spec(1, bold = TRUE, italic = TRUE) %>%
  row_spec(2:3, color = 'white', background = 'black') %>%
  row_spec(4, underline = TRUE, monospace = TRUE) %>%
  row_spec(5, angle = 45) %>%
  column_spec(5, strikeout = TRUE)
```

- Alterar o tamanho da tabela, preenche todo espaço disponível (**full_width**).

```
kable(head(dados, 10), col.names = c("Gênero", "Álcool", "Memória", "Latência")) %>%
  kable_styling(full_width = FALSE)
```

- **bootstrap_options**

- Cores alternadas entre linhas (**bootstrap_options** = c("striped")).

```
kable(head(dados, 10), col.names = c("Gênero", "Álcool", "Memória", "Latência")) %>%
  kable_styling(full_width = F, bootstrap_options = c("striped"))
```

- Deixando a tabela mais condensada/junta (**bootstrap_options** = c("striped", "condensed")).

```
kable(head(dados, 10), col.names = c("Gênero", "Álcool", "Memória", "Latência")) %>%
  kable_styling(full_width = F, bootstrap_options = c("striped", "condensed"))
```

- Agrupar linhas e colunas.

Podemos agrupar conjunto de linhas, ou colunas, e dar um cabeçalho para elas.

- Agrupar colunas:

Através da função **add_header_above** podemos dar nome aos agrupamentos e definir o número de colunas agrupadas.

```
iris2 <- iris[1:5, c(1, 3, 2, 4, 5)]
names(iris2) <- gsub('[.].+', '', names(iris2))
kable(iris2, booktabs = TRUE) %>%
  add_header_above(c("Length" = 2, "Width" = 2, " " = 1)) %>%
  add_header_above(c("Measurements" = 4, "More attributes" = 1))
```

- Agrupar linhas:

Através da função **pack_rows** e do argumento **index** podemos dar nome aos agrupamentos e definir o número de linhas agrupadas.

```
iris3 <- iris[c(1:2, 51:54, 101:103), ]
kable(iris3[, 1:4], booktabs = TRUE) %>%
  pack_rows(index = c("setosa" = 2, "versicolor" = 4, "virginica" = 3))
```

7.7.3.3.3 xtable

- A biblioteca **xtable** converte um objeto R em um objeto **xtable**, que pode ser expresso como uma tabela **LaTeX** ou **HTML**.
- Dentro do *chunk*, podemos chamar a biblioteca **xtable**, e usar a função **xtable()**, que recebe como argumentos a variável **dataframe** (e outras funções) e o *tipo* da saída para a tabela (**LaTeX** ou **HTML**).

```
library(xtable)
xtable(dataframe, type = "latex")
```

```
library(xtable)

coluna1 <- c(1,2,3,4,5,6)
coluna2<- c("a","b","c","d","e","f")
tab <- data.frame(coluna1,coluna2)

xtable(tab,type = "latex")
xtable(tab,type = "html")
```

7.7.3.3.4 **pander**

- O principal objetivo do pacote **pander** R é oferecer uma ferramenta de fácil renderização de objetos R no markdown do Pandoc.
- Um dos recursos mais populares do **pander** é `pandoc.table`, renderizando a maioria dos objetos R tabulares em tabelas de remarcação com várias opções de configuração:

- *Style* (**Estilo**)

- * “*simple*”
style = "simple"
 - * “*grid*”
style = "grid"
 - * “*markdown*”
style = "markdown"

- *Caption* (**Legenda**)

- caption = "Legenda"

- *Highlighting cells* (**Celulas destacadas**)

- Comandos para destacar linhas, colunas e células.

- As células podem estar em negrito e itálico ao mesmo tempo.

- * Italics (*italico*):
emphasize.italics.rows(1)
emphasize.italics.cols(2)
emphasize.italics.cells(which(t > 20, arr.ind = TRUE))
 - * strong (**negrito**):
emphasize.strong.rows(1)
emphasize.strong.cols(1)
emphasize.strong.cells(which(t > 20, arr.ind = TRUE))
 - * verbatim (estilo literal):
emphasize.verbatim.rows(1)
emphasize.verbatim.cols(2)
emphasize.verbatim.cells(which(t > 20, arr.ind = TRUE))
Exemplo:
emphasize.italics.cols(1)
emphasize.italics.rows(1)
emphasize.strong.cells(which(t > 20, arr.ind = TRUE))
pandoc.table(t)

- *Justify* (**Alinhamento da célula**)

- * Opções de alinhamento de célula:

- “*right*”
 - “*left*”

- “center”

* Formas de alinhamento de célula:

- Alinhando tudo de uma vez:
`justify = "right"`
- Alinhando cada coluna separadamente:
`justify = c("right","center","left")`

– *Table and Cell width* (**Largura**)

* `split.table` (**Largura tabela**) A largura máxima da tabela são 80 caracteres, caso ultrapasse esse tamanho, a tabela será quebrada e a parte excendente será inserida abaixo, como uma continuação. Para desligar essa opção e aumentar o tamanho da tabela, basta adicionar a opção *Inf*.

`split.table = Inf`

* `split.cell` (**Largura célula**) O tamanho máximo da célula são 30 caracteres, caso ultrapasse esse tamanho, o texto será quebrado e adicionado a baixo, ainda na célula.

Para ajustar o tamanho da célula (definir o número de caracteres) existem três opções:

- Todas de uma vez.
`split.cell = 40`
- Coluna por coluna.
`split.cell = c(40,20,5)`
- Em termos de porcentagem.
`split.cell = "40%"`
`split.cell = c("80%","20%","40%")`

• Exemplo:

`library(pander)`

`pandoc.table(dataframe, justify = "center", caption = "Exemplo de tabela")`

7.7.3.4 Tabela para paginas web

- Dentro do *chunk*, podemos chamar a biblioteca **rmarkdown**, e usar a função **paged_table()**, onde podemos chamar como argumento a variável **dataframe**.
- Esse tipo de tabela é ideal para aplicações *web*.
- Separa os dados por páginas, de maneira dinâmica e com interação do usuário.
- Mostra dez linhas por página.
- Exemplo:
library(rmarkdown)
paged_table(var_dataframe)

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	
Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	
Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	
1-5 of 32 rows 1-10 of 12 columns			Previous 1 2 3 4 5 6 7 Next							

Figure 2: Exemplo tabela paged_table

7.8 Hiperlinks e imagens

7.8.1 Hiperlinks

- Sintaxe:
[Nome do Link](Endereço do Link)
- Exemplo:
Canal do YouTube

7.8.2 Imagens

- Existem duas formas de pegar uma imagem são elas:
 - Pegar a imagem de um endereço da web (igual a hiperlink).
!`[Legenda](https://miro.medium.com/max/600/1*sCJzUnDilAuvGr11lJeXKw.jpeg)`
 - Pegar a imagem de uma pasta no computador (adicionar caminho ate a imagem).
!`[Legenda](Cap4-R_markdown/RMarkdown.png)`
- Sintaxe:
!`[Legenda](Endereço da Imagem)`
- Exemplo:



Figure 3: Logo do R Markdown

7.9 Fórmulas LaTeX

7.9.1 Equações

- As equações no **R Markdown** são escritas com a linguagem **LaTeX**.
- Para que a equação apareça no meio do texto, devemos escrevê-la entre dois cifrões: `$equação$`
- Para que a equação apareça no formato destacado (display), deve ser colocada entre quatro cifrões: `$$equação$$`

7.9.2 Superescrito e subscritos

- Superescrito `a^2` = a^2
- Subscrito `a_2` = a_2
- Agrupado `a^{2+2}` = a^{2+2}
- Subscrito dois índices `$a_{i,j}$` = $a_{i,j}$
- Combinando super e subscrito `a_2^3` = a_2^3
- Derivadas `x'` = x'

7.9.3 Sublinhados, sobrelinhas e vetores

Fórmula	Símbolo
<code>\$\hat a\$</code>	$\hat a$
<code>\$\bar b\$</code>	$\bar b$
<code>\$\overrightarrow{a b}\$</code>	\overrightarrow{ab}
<code>\$\overleftarrow{c d}\$</code>	\overleftarrow{cd}
<code>\$\widehat{d e f}\$</code>	\widehat{def}
<code>\$\overline{g h i}\$</code>	\overline{ghi}
<code>\$\underline{j k l}\$</code>	\underline{jkl}

7.9.4 Frações, matrizes e chavetas

- Fração:
 $\frac{1}{2}$

- pmatrix:

```
 $\begin{pmatrix} x & y \\ z & v \end{pmatrix}$ 
```

$$\begin{pmatrix} x & y \\ z & v \end{pmatrix}$$

- bmatrix:

```
 $\begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}$ 
```

$$\begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}$$

- Bmatrix:

```
 $\begin{Bmatrix} x & y \\ z & v \end{Bmatrix}$ 
```

$$\begin{Bmatrix} x & y \\ z & v \end{Bmatrix}$$

- vmatrix:

```
 $\begin{vmatrix} x & y \\ z & v \end{vmatrix}$ 
```

$$\begin{vmatrix} x & y \\ z & v \end{vmatrix}$$

- Vmatrix:

```
 $\begin{Vmatrix} x & y \\ z & v \end{Vmatrix}$ 
```

$$\begin{Vmatrix} x & y \\ z & v \end{Vmatrix}$$

$$\begin{vmatrix} x & y \\ z & v \end{vmatrix}$$

- matrix:

```

 $\begin{matrix} x & y \\ z & v \end{matrix}$ 

```

```

 $x \quad y$ 
 $z \quad v$ 

```

7.9.5 Expressões

- Combinação

$$\${n \choose k} = \binom{n}{k}$$

- Função piso

$$\${\lfloor x \rfloor} = \lfloor x \rfloor$$

- Função teto

$$\${\lceil x \rceil} = \lceil x \rceil$$

- Sobrechaves

$$\${\overbrace{1+2+\cdots+100}}^{5050} = \overbrace{1+2+\cdots+100}^{5050}$$

- Sobchaves

$$\${\underbrace{1+2+\cdots+100}_{5050}} = \underbrace{1+2+\cdots+100}_{5050}$$

- Função por partes

$$f(n) = \begin{cases} n/2, & \text{se } n \text{ é par} \\ 3n+1, & \text{se } n \text{ é ímpar} \end{cases}$$

$$f(n) = \begin{cases} n/2, & \text{se } n \text{ é par} \\ 3n+1, & \text{se } n \text{ é ímpar} \end{cases}$$

- Limites

$$\${\lim_{n \rightarrow \infty} x_n} = \lim_{n \rightarrow \infty} x_n$$

- Integral

$$\int_{-N}^N e^x dx = \int_{-N}^N e^x dx$$

- Integral Linear

$$\oint_C x^3 dx + 4y^2 dy = \oint_C x^3 dx + 4y^2 dy$$

- Integral Múltipla

$$\iiint_V \mu(u,v,w) du dv dw = \iiint_V \mu(u,v,w) du dv dw$$

- Somatório

$$\sum_{k=1}^N k^2 = \sum_{k=1}^N k^2$$

- Somatório com dois índices

$$\sum_{\substack{0 < i < m \\ 0 < j < n}} k_{i,j} = \sum_{\substack{0 < i < m \\ 0 < j < n}} k_{i,j}$$

- Produtório

$$\prod_{i=1}^N x_i = \prod_{i=1}^N x_i$$

- Raiz n-ésima

$$f(x) \approx \sqrt[n]{x} = f(x) \approx \sqrt[n]{x}$$

7.9.6 Sinais e setas

- Principais sinais e setas:

Fórmula	Símbolo
<code>\sim</code>	\sim
<code>\simeq</code>	\simeq
<code>\cong</code>	\cong
<code>\leq</code>	\leq
<code>\geq</code>	\geq
<code>\equiv</code>	\equiv
<code>\approx</code>	\approx
<code>\neq</code>	\neq
<code>\leftarrow</code>	\leftarrow
<code>\rightarrow</code>	\rightarrow
<code>\leftrightarrow</code>	\leftrightarrow
<code>\longleftarrow</code>	\longleftarrow
<code>\longrightarrow</code>	\longrightarrow
<code>\mapsto</code>	\mapsto
<code>\longmapsto</code>	\longmapsto
<code>\nearrow</code>	\nearrow
<code>\searrow</code>	\searrow
<code>\swarrow</code>	\swarrow
<code>\nwarrow</code>	\nwarrow
<code>\uparrow</code>	\uparrow
<code>\downarrow</code>	\downarrow
<code>\updownarrow</code>	\updownarrow

- Guia de fórmulas:
http://pt.wikipedia.org/wiki/Ajuda:Guia_de_ediç~ao/Fórmulas_TeX

7.10 Letras gregas

- Expressões matemáticas, ou letras gregas, devem vir entre símbolos de \$.

Fórmula	Símbolo
<code>\$\alpha\$</code>	α
<code>\$\beta\$</code>	β
<code>\$\gamma\$</code>	γ
<code>\$\delta\$</code>	δ
<code>\$\epsilon\$</code>	ϵ
<code>\$\varepsilon\$</code>	ε
<code>\$\zeta\$</code>	ζ
<code>\$\eta\$</code>	η
<code>\$\theta\$</code>	θ
<code>\$\vartheta\$</code>	ϑ
<code>\$\iota\$</code>	ι
<code>\$\kappa\$</code>	κ
<code>\$\lambda\$</code>	λ
<code>\$\mu\$</code>	μ
<code>\$\nu\$</code>	ν
<code>\$\xi\$</code>	ξ
<code>\$\pi\$</code>	π
<code>\$\varpi\$</code>	ϖ
<code>\$\rho\$</code>	ρ
<code>\$\varrho\$</code>	ϱ
<code>\$\sigma\$</code>	σ
<code>\$\varsigma\$</code>	ς
<code>\$\tau\$</code>	τ
<code>\$\upsilon\$</code>	υ
<code>\$\phi\$</code>	ϕ
<code>\$\varphi\$</code>	φ
<code>\$\chi\$</code>	χ
<code>\$\psi\$</code>	ψ
<code>\$\omega\$</code>	ω

- Para letra maiúscula, inicie a letra na fórmula com letra maiúscula.
 $\delta = \text{\texttt{$\delta$}}$
 $\Delta = \text{\texttt{$\Delta$}}$

7.11 Formatação (Fontes)

- Para deixar uma palavra em **negrito**, coloque-a entre quatro asteriscos: ****negrito****.
- Para deixar uma palavra em *itálico*, coloque-a entre dois asteriscos: **itálico**.
- Para deixar uma palavra em ~~tachado~~, coloque-a entre dois til: ~~~~tachado~~~~.
- Para deixar caracteres ^{sobrescritos}, coloque-os entre acentos circunflexos: ^{^1^}.
- Para deixar caracteres _{subscritos}, coloque-os entre til: _{~1~}.
- Outra forma de escrever subscritos₂ (forma *LaTeX*), colocar no formato subscrito equação do *LaTeX*: `subscrito$_{2}$`.
- Para destacar um termo como código, coloque-o entre crases (backticks): ``código``.
- Para criar uma citação (quote), escreva o texto após um sinal de maior: `> Citação`.

7.12 Abas

- Aplica a um `#titulo` um comando (`{.tabset}`) que transforma em abas os `##subtitulo` com os gráficos e tabelas contidos neles.
- Muito útil para relatórios dinâmicos (**html**).
- Exemplo:
`# titulo {.tabset}`

8 Cap 5 - Pacotes do Tidyverse e identificando/mudando tipos de variáveis

8.1 Identificando/mudando tipos de variáveis

- i. Principais tipos de variáveis:

Table 6: Principais tipos de dados

Tipo	Descrição
numeric	Pode ser tanto inteiro (int, ou integer) quanto float (dbl).
character	São caracteres (chr).
factor	São variáveis do tipo fator.
logical	Variáveis do tipo lógico: TRUE ou FALSE.
complex	No formato de números complexo: $4 + 5i$.

- ii. Identificando o tipo da variável:
Uso do `is`.

```
is.numeric(variavel)
[TRUE]
```

- iii. Mudando o tipo da variável:
Uso do `as`.
`as.character(variavel)`

- iv. Observações:

- Não é possível transformar uma variável do tipo `character(character)` direto para tipo número (`numeric`), é preciso transformar de `character(character)` para `fator(factor)` e de `fator(factor)` para número (`numeric`).

```
is.character(variavel)
[TRUE]
as.factor(variavel)
as.numeric(variavel)
```

- O contrário, transformar de número (`numeric`) para `character(character)` é possível.

```
is.numeric(variavel)
[TRUE]
as.character(variavel)
```

8.2 Pacotes do Tidyverse

- **readr**
Leitura de dados.
- **tibble**
Tipo de data.frame.
- **magrittr**
Operador pipe %>%, concatena linhas de comando.
- **dplyr**
Manipulação de dados.
- **tidyr**
Organização de dados.
- **ggplot2**
Elaboração de gráficos.

8.3 Leitura de dados (readr)

- Os principais formatos de importação de dados são:
 - *csv*
 - *xls*
 - *xlsx*
 - *sav*
 - *dta*
 - *por*
 - *sas*
 - *stata*
- Entre os principais formatos de importação de dados o mais usado é o *csv*.

8.3.1 Importação de dados via RStudio

- No “**Environment**” tem a opção “**Import Dataset**”, que pode ser usada para importação de dados “.csv”.
“**Environment**” > “**Import Dataset**” > “**From Text (Readr)**”
- Dentro de “**Import Text Data**”:
 - **File/URL**
O caminho ate o arquivo “.csv”.
 - **Data Preview**
Mostra uma prévia de como os dados serão lidos (ficarão organizados no **R**). Se não estiver visualizando, aperte o botão **update**.
 - **Import Options**
São as configurações que podem ser modificadas para garantir a integridade da importação dos dados.
Definindo, por exemplo, se o que separa casas decimais nos dados é virgula ou ponto.
 - **Code Preview**
Apresenta o código que esta sendo construido pela automatização da janela. Este código pode ser copiado e executado fora da janela.
 - **Import**
Botão para concluir a operação da importação dos dados.

8.3.2 Importação de dados via biblioteca readr

- As principais funções de importação de arquivo *.csv* são:
 - `read.csv`
É uma função básica do **R**, não precisa chamar nenhuma biblioteca. Usa o separador de campos vírgula.
 - `read.csv2`
É uma função básica do **R**, não precisa chamar nenhuma biblioteca. Usa o separador de campos ponto e vírgula.
 - `readr::read_csv`
É uma função do pacote **readr**, por isso o uso de “`readr::`” para chamar a função. Usa o separador de campos vírgula.
 - `readr::read_csv2`
É uma função do pacote **readr**, por isso o uso de “`readr::`” para chamar a função. Usa o separador de campos ponto e vírgula.
 - `readr::read_tsv`
É uma função do pacote **readr**, por isso o uso de “`readr::`” para chamar a função. Usa o separador de campos tabulação.
 - `readr::read_delim`
É uma função do pacote **readr**, por isso o uso de “`readr::`” para chamar a função. Usa o separador de campos genérico, deve ser especificado pelo parâmetro `delim =`.
- Principais parâmetros, das funções de importação, do pacote **readr**:
 - `file =`
Define o caminho (ou **URL**), que deve ser percorrido, e o arquivo, no formato *.csv*, a ser importado. Deve estar entre aspas.
Exemplo: `file = "Caminho/arquivo.csv"`
 - `col_names =`
Indica se a primeira linha contém, ou não, o nome das colunas. Também pode ser usado para renomear colunas.
Se a primeira linha contém o nome das colunas = **TRUE**.
Para nomear, ou renomear, colunas podemos usar um vetor contendo os nomes.
Exemplo:
`col_names = TRUE`
`col_names = c("coluna_1", "coluna_2", ...)`
 - `col_types =`
Caso alguma coluna tenha sido importada com a classe errada, podemos usar esse parâmetro para mudar e especificar o tipo de cada coluna.
Podemos especificar através de uma lista contendo as classes de cada coluna, ou uma cadeia de caracteres com caracteres simbólicos para cada classe de cada coluna.
Outra possibilidade é mudar as classes através de funções de mudança de classe, usando a função `cols()`, onde `.default =` indica a classe default de importação, para casos não especificados, e caso precisarmos identificar uma coluna em específico `nome_da_coluna =`.

* Caracteres simbólicos:

- c = character
- i = integer
- n = number
- d = double
- l = logical
- f = factor
- D = date
- T = date time
- t = time
- ? = guess
- _or_ = skip

* Funções de mudança de classe:

- col_character()
- col_date()
- col_time()
- col_datetime()
- col_double()
- col_factor()
- col_integer()
- col_logical()
- col_number()
- col_skip()

* Exemplos:

```
col_types = "iccd"  
col_types = cols(.default = "i", xxx = "c")  
col_types = cols(.default = col_integer(), xxx = col_character())
```

– skip =

Pula linhas do começo do arquivo antes de iniciar a importação. Útil quando tem algum texto explicativo na primeira linha do arquivo.

Exemplos:

`skip = 0`

`skip = 1`

– `na =`

Indica quais *strings* deverão ser tratadas como **NA** na hora da importação.

Exemplo: `na = c("", "NA")`

– `delim =`

No caso da função `read_delim`, podemos definir através deste parâmetro o tipo de delimitador de campos usado no arquivo. O caractere usado como delimitador de campo deve estar entre aspas.

Exemplo: `delim = ","`

- Sintaxe:

```
library(readr)
dt <- read_csv2(file = "~/caminho/arquivo.csv",
  col_names = TRUE,
  col_types = "iccd",
  na = c("", "NA"),
  skip = 0)
```

- Observação:

Por padrão *csv* usa separação por vírgula, porém no Brasil como a vírgula é usada para separação de casas decimais, o padrão *csv* brasileiro o separador de campo é o ponto e vírgula, sendo assim, para importar dados em formato *csv* no Brasil a melhor escolha é o pacote `readr::read_csv2`.

8.3.3 Sincronização com banco de dados

- Drives **ODBC** é um conector com banco de dados.
 - instalando **ODBC** no linux/Ubuntu:
`sudo apt-get install unixodbc unixodbc-dev --install-suggests`
 - Instalação de cada ODBC separadamente:
 - * SQL Server ODBC Drivers (Free TDS)
`sudo apt-get install tdsodbc`
 - * PostgreSQL ODBC Drivers
`sudo apt-get install odbc-postgresql`
 - * MySQL ODBC Drivers
`sudo apt-get install libmyodbc`
 - * SQLite ODBC Drivers
`sudo apt-get install libsqliteodbc`
 - É necessário configurar dois arquivos `odbcinst.ini` e `odbc.ini`.

* `odbcinst.ini`

```
[PostgreSQL Driver]
Driver              = caminho/psqlodbcw.so
[SQLite Driver]
Driver              = caminho/libsqlite3odbc.dylib
```

* `odbc.ini`

```
[PostgreSQL]
Driver              = PostgreSQL Driver
Database            = test_db
Servername          = localhost
Username            = postgres
Password            = password
Port                = 5432
```

```
[SQLite]
Driver              = SQLite Driver
Database            = /tmp/testing
```

- O pacote **DBI** ajuda a conectar o **R** aos sistemas de gerenciamento de banco de dados (DBMS).
- Conectando com banco de dados **Postgres**:

```
con <- DBI::dbConnect(odbc::odbc(),
                      Driver   = "PostgreSQL Driver",
                      Server   = "localhost",
```



```
Database = "name_database",  
UID      = rstudioapi::askForPassword("Database user"),  
PWD      = rstudioapi::askForPassword("Database password"),  
Port     = 5432)
```

- Referência:
<http://db.rstudio.com/>

8.4 tibble

8.4.1 Visualização de tabelas tipo tibble

- *tibble* é um tipo especial de tabela equivalente ao *data.frame*, porem mais compacta e com mais informações.
- O *tibble* exibe informações sobre os tipos de cada variável:
 - *factor*(**fct**)
 - *character*(**chr**)
 - *integer*(**int**)
 - *double*(**dbl**)
- Visualização da tabela:
- O *tibble* também omite linhas quando a tabela é muito numerosa, para melhor visualização.
- O *tibble* por **default** exibira ate 10 linhas.

```
library(tibble)
dt <- tibble(dados)
dt
```

- Caso necessite ver mais linhas basta especificar.
`print(dt, n=15)`

8.4.2 Criação de tabela tipo tibble

- Primeiramente é necessario chamar a biblioteca **tibble**
`library(tibble)`
- De forma semelhante ao **data.frame**, podemos criar tabelas do tipo **tibble**.
`x = tibble(coluna1 = c(...), coluna2 = c(...), ...)`

8.4.3 Funções tibble

- `as_tibble()`
 - Transforma um **data.frame** em tipo **tibble**, através da função `as_tibble()`.
`x <- as_tibble(x)`
- `is_tibble()`
 - Verifica se uma tabela é tipo **tibble**, através da função `is_tibble()`. Retorna **TRUE** (se verdadeiro), ou **FALSE** (se falso).
`is_tibble(x)`
- `add_column()`
 - Adiciona novas colunas.

```
dados1 %>%  
add_column(nome = valor)
```

 - Também é possível definir a posição onde a nova coluna vai se encaixar, indicando a posição (`.before = 1` ou `.after = 1`).

```
dados1 %>%  
add_column(nome = valor, .before = 1)
```
- `add_row()`
 - Adiciona novas linhas.
 - Também é possível definir a posição da nova linha através dos comandos `.before` ou `.after`.
 - É necessário adicionar as informações e referenciar as colunas.

```
dados1 %>%  
add_row(cupom = 100, filial = "A",  
valor_compra = 10, n_itens = 1,  
desconto_perc = 0, quinzena = 1,  
.before = 1)
```

8.5 Operador pipe

- Esta contido do pacote `magrittr`.
- Funciona como uma função composta, tornando a leitura das linhas de comando mais lógica e natural.
- Trata-se de um operador cuja notação é `%>%`. Com ele podemos encadear (concatenar) linhas de comandos na ordem de execução.
- Atalho no teclado `ctrl+shift+M`.
- Exemplo:

```
library(magrittr)
library(dplyr)

dados1 %>%
  select(filial,quinzena) %>%
  filter(quinzena == 1)
```

8.6 Manipulando dados com o dplyr

8.6.1 manipulação de dados:

- `select()`

- Seleciona e retorna as colunas selecionadas da tabela.
- Retorna as colunas selecionadas no formato tabela.
- Pode retornar mais de uma coluna.
- Exemplo:

```
library(dplyr)
library(magrittr)
dados1 %>%
  select(filial,quinzena,valor_compra)
```

- `pull()`

- Extrai uma coluna de uma tabela de dados e retorna ela como vetor.
- A coluna identificada para extração pode ser tanto pelo nome, quanto pela posição.
- Retorna apenas uma coluna, no formato vetor.
- Exemplo:

```
library(dplyr)
library(magrittr)
vetor <- dados1 %>%
  pull(filial)
ou,
pull(2)
ou,
pull(-5)
```

- `filter()`

- Filtra linhas.

- Exemplo:

```
library(dplyr)
library(magrittr)
dados1 %>%
  filter(filial == "A")
```

- Principais operadores lógicos:

Table 7: Tabela dos principais operadores lógicos usados na função `filter`.

Operador lógico	Descrição
<code>==</code>	Igualdade
<code>!=</code>	Diferença
<code>></code>	Maior que
<code><</code>	Menor que
<code>>=</code>	Maior ou igual que
<code><=</code>	Menor ou igual que
<code>&</code>	E
<code> </code>	OU
<code>!</code>	Negação

- `distinct()`

- Remove linhas com valores repetidos de determinadas colunas.

- Podemos extrair todas as linhas distintas , do banco de dados, pelo comando `distinct()`, apenas não especificando as colunas.

- Exemplo:

```
library(dplyr)
library(magrittr)
dados1 %>%
  distinct(filial)
ou,
distinct(filial, quinzena, desconto_perc)
ou,
distinct()
```

- `arrange()`

- Reordena em determinadas colunas as linhas.

- Pode reordenar mais de uma coluna por vez.

- `arrange(coluna_1,coluna_2,...)`

- ou

- `arrange(coluna_1) %>%`

- `arrange(coluna_2)`

- A ordem das colunas na função determina a prioridade na ordenação.

- Por **default** reordena as linhas em ordem crescente.

- Podemos também reordenar as linhas em ordem decrescente:

- * `arrange(-nome_coluna)`

- Colocando um sinal de negativo na frente da coluna é informar ordenar em decrescente.

- * `arrange(desc(nome_coluna))`

- Usando a função `desc()`.

- Exemplo:

- `library(magrittr)`

- `library(dplyr)`

- `dados1 %>%`

- `arrange(n_itens,valor_compra) %>%`

- `filter(valor_compra > 100) %>%`

- `select(filial,n_itens,valor_compra)`

- `mutate()`

- Cria novas colunas, na base de dados.

- Exemplo:

```
library(magrittr)
library(dplyr)
```

```
dados1 %>%
mutate(vmci = round(valor_compra/n_itens))
```

- `transmute()`

- Cria novas colunas, mas não adiciona na base de dados.

- A diferença de `transmute()` para `mutate()` é que em `mutate()` acrescenta novas colunas aos dados originais, enquanto que em `transmute()` criamos novas colunas a partir dos dados originais.

- Exemplo:

```
library(magrittr)
library(dplyr)
```

```
dados1 %>%
transmute(vmci = round(valor_compra/n_itens))
```


- `summarise()`

- Permite sumarizar variáveis, ou seja, produzir tabelas resumidas do banco de dados.
- Pode ser usado em conjunto com o comando `group_by()` para obter o resumo de grupos.
- Sintaxe:
`summarise(nome_da_coluna = função_summarise(coluna))`
- Exemplo:

```
dados1 %>%
select(filial) %>%
summarise(item_total = sum(n_itens))
```

ou

```
dados1 %>%
group_by(filial) %>%
summarise(cupons_distintos = n_distinct(cupom))
```

- Principais funções de sumarização:

Table 8: Principais funções de `summarise`

Funções	Descrição
<code>n()</code>	Conta o número de elementos da coluna x
<code>n_distinct(x)</code>	Conta os elementos distintos da coluna x
<code>sum(x)</code>	Soma os valores da coluna x, retorna o acumulado
<code>mean(x)</code>	Cálcula a média da coluna x
<code>median(x)</code>	Cálcula a mediana da coluna x
<code>quantile(x,k)</code>	Cálcula o percentil de ordem $0 \leq k \leq 1$ dos valores da coluna x
<code>min(x)</code>	Retorna o valor mínimo da coluna
<code>max(x)</code>	Retorna o valor máximo da coluna
<code>var(x)</code> ou <code>var(x,y)</code>	Cálcula a variância da coluna x, ou a covariância da coluna x em relação a coluna y
<code>sd(x)</code>	Cálcula o desvio-padrão da coluna x
<code>prod(x)</code>	Multiplica os valores da coluna x

- `group_by()`

- Permite operações por grupo. Agrupa dados de determinadas colunas.
- Agrupa as colunas priorizando a ordem em que aparecem na função.
- Exemplo:
`group_by(coluna1,coluna2,...)`

- `rename()`
 - Renomeia uma coluna.
`rename(novo_nome = antigo_nome)`
 - Pode renomear várias colunas de uma vez.

```
dados1 %>%  
rename(x1 = coluna1, x2 = coluna2, ...)
```

8.6.2 combinando tabelas de dados:

- `bind_cols()`

- Une duas tabelas lado a lado, sobrepostas. Ou seja, soma o número de colunas das duas tabelas.
- Acrescenta numeração as colunas repetidas. Ou seja, se houver a mesma coluna nas duas tabelas, será acrescentado ao nome das colunas repetidas um valor.
- É necessário que tenha o mesmo número de linhas nas duas tabelas para fazer essa combinação.
- Dentro da função, a ordem de chamada de cada tabela determina a ordem das colunas.
- Exemplo:

```
library(tibble)
library(magrittr)
library(dplyr)
x <- dados1 %>%
  select(cupom,filial,valor_compra)
y <- dados1 %>%
  select(cupom,n_itens)
z <- bind_cols(x,y)
colnames(z)

[1] "cupom...1" "filial" "valor_compra" "cupom...4" "n_itens"
```

- `bind_rows()`

- Une duas tabelas pelas linhas.
- Não é necessário que o número de linhas, ou colunas, seja igual nas duas tabelas. Nesse ponto é diferente do comando `bind_cols()`.
- As colunas das duas tabelas são combinadas, porém das colunas repetidas é mantida apenas uma.
- Quando não há correspondência entre as colunas o comando retorna **NA**, no valor específico da linha.
- Dentro da função, a ordem de chamada de cada tabela determina a ordem das colunas.
- Exemplo:

```
library(tibble)
library(magrittr)
library(dplyr)
x <- dados1 %>%
  select(cupom,filial,valor_compra)
y <- dados1 %>%
  select(cupom,n_itens)
z <- bind_rows(x,y)
```

```
colnames(z)
[1] "cupom" "filial" "valor_compra" "n_itens"
```

- `inner_join()`
 - A tabela final será o resultado da intersecção das colunas de x e y, que possuem pelo menos uma coluna em comum, a coluna *chave*.
 - Junta duas colunas pela intersecção.
 - Ao juntar as duas tabelas pela função `inner_join()`, apenas os registros que existam nas duas tabelas (pela coluna chave) são unidos, os demais registros de cada tabela não são agregados.
 - Os filtros (`filter()`) aplicados a cada tabela são somados.
 - Exemplo:

```
x = dados1 %>%
select(cupom, filial, valor_compra) %>%
filter(valor_compra >500)
x
y = dados1 %>%
select(filial,n_itens) %>%
filter(n_itens < 8)
y
inner_join(x,y)
```
- `left_join()`
 - Une duas tabelas, definindo qual será a tabela principal (tabela da **esquerda**).
 - Apresenta e prioriza os registros da tabela principal (tabela da **esquerda**).
 - O resultado final reúne todos os registros da tabela principal e os correspondentes na outra tabela.
 - É necessário que tenha pelo menos uma coluna em comum, a coluna chave.
 - Exemplo:

```
left_join(tabela_principal, tabela_secundaria)
```
- `right_join()`
 - Une duas tabelas, definindo qual será a tabela principal (tabela da **direita**).
 - Apresenta e prioriza os registros da tabela principal (tabela da **direita**).
 - O resultado final reúne todos os registros da tabela principal e os correspondentes na outra tabela.
 - É necessário que tenha pelo menos uma coluna em comum, a coluna chave.
 - Exemplo:

```
right_join(tabela_secundaria, tabela_principal)
```
- `full_join()`
 - Une duas tabelas.
 - Mantem todos os registros.

- Prestar atenção na junção das linhas/registros que formam novas informações, através da combinação de correspondentes.
- Os registros sem correspondentes na outra tabela são preenchidos com valor **NA**.
- É necessário que tenha pelo menos uma coluna em comum, uma coluna chave.
- Exemplo:

```
x <- dados1 %>%  
select(cupom,filial,valor_compra) %>%  
filter(valor_compra > 500)  
  
y <- dados1 %>%  
select(filial,n_itens) %>%  
filter(n_itens < 8)  
  
full_join(x,y)
```

- `intersect()`
Retorna a interseção entre tabelas.
`intersect(x,y)`
- `union()`
 - Retorna a união de tabelas.
 - Não repete registros iguais nas duas tabelas.
 - Monta a nova tabela na ordem em que as tabelas foram inseridas na função.
 - Exemplo:
`union(x,y)`
- `setdiff()`
 - Retorna a diferença entre tabelas.
 - A ordem das tabelas na função interfere na saída:
 - * `setdiff(x,y)`
Retorna tudo que esta em x e não esta em y.
 - * `setdiff(y,x)`
Retorna tudo que esta em y e não esta em x.
- `setequal()`
 - Esse comando verifica se duas tabelas de dados possuem linhas com os mesmos valores, independentemente da ordem em que tais valores se apresentem.
 - Retorna **TRUE**, se os registros forem iguais, ou **FALSE**, se os registros forem diferentes.
 - Sintaxe:
`setequal(tabela_1,tabela_2)`

8.7 Organizando dados com o tidyr

- `pivot_longer()` ou `gather()`
 - Converte a tabela de dados do formato larga para o formato longo. (larga -> longo)
 - A função `pivot_longer()` substituiu a função `gather()`, após o ano de 2019.
 - Transformação:
 - * Converte várias colunas do dataframe original em duas colunas e várias linhas/registros.
 - * Uma coluna recebe o nome das variáveis em colunas e a outra recebe os valores dessas variáveis.
 - * Ao final o número de linhas do dataframe é ampliado e o número de colunas diminuiu.
 - Condição:
 - * As colunas originais devem ter em comum a mesma variável.
 - * Pelo menos duas colunas contendo os nomes das categorias de uma variável separados por colunas.
 - Sintaxe:

```
tabela_longa <- tabela_larga %>% pivot_longer(cols = c(coluna_4,coluna_5)),
names_to = "nova_coluna_1", values_to = "nova_coluna_2")
```

 - * `cols`
Recebe as colunas que vão ser transformadas em linhas.
 - * `names_to`
Nome da nova coluna que vai receber como variável o nome das colunas originais.
 - * `values_to`
Nome da nova coluna que vai receber os valores contidos nas colunas originais.
 - Exemplo:

Table 9: Tabela de chegada de turistas no formato larga

Estado	Terrestre	Aéreo
SP	3900	4200
RS	2800	3800
RJ	2600	3950

Table 10: Tabela de chegada de turistas no formato longo

Estado	Meio	Chegada
SP	Terrestre	3900
SP	Aereo	4200
RS	Terrestre	2800

Estado	Meio	Chegada
RS	Aereo	3800
RJ	Terrestre	2600
RJ	Aereo	3950

- `pivot_wider()` ou `spread()`
 - Converte a tabela de dados do formato longo para o formato larga. (longo -> larga)
 - A função `pivot_wider()` substituiu a função `spread()`, após o ano de 2019.
 - As funções `pivot_wider()` e `spread()`, faz o inverso das funções `pivot_longer()` e `gather()`, ou seja, espalha os dados das linhas por colunas.
 - Transformação:
 - * Converte várias linhas do dataframe original em colunas.
 - Sintaxe:

```
tabela_larga <- tabela_longa %>% pivot_wider(names_to = "coluna_4", values_to = "coluna_5")
```

 - * `names_to`
Determina qual coluna terá seus valores transformados em novas colunas.
 - * `values_to`
Determina qual coluna terá seus valores distribuidos entre as novas colunas.
 - Exemplo:

Table 11: Tabela em formato longo dieta de pacientes

Pacientes	Tempo	Sexo	dieta	Peso
1	4	Homem	Antes	150
2	4	Homem	Antes	160
3	3	Mulher	Antes	90
4	3	Mulher	Antes	95
5	6	Mulher	Antes	110
1	4	Homem	Depois	140
2	4	Homem	Depois	110
3	3	Mulher	Depois	80
4	3	Mulher	Depois	80
5	6	Mulher	Depois	82

Table 12: Tabela em formato larga dieta de pacientes

Pacientes	Tempo	Sexo	Antes	Depois
1	4	Homem	150	140
2	4	Homem	160	110
3	3	Mulher	90	80
4	3	Mulher	95	80
5	6	Mulher	110	82

- `separate()`
 - Separa os dados contidos numa mesma coluna para diversas colunas.
 - Transforma um campo vetorizado em diversas colunas separadas.
 - É necessário determinar o separador, o caracter que separa os dados dentro do campo.
 - Argumentos:
 - * Coluna que vai ter seus dados separados.
 - * Novas colunas que vão receber os dados.
 - * Caracter que separa os dados na coluna original.
 - Exemplo:


```
resposta <- dados %>% separate(cor, c("cor1","cor2"), sep = ",")
```
- `unite()`
 - O comando `unite()` é utilizado para unir duas ou mais colunas em uma unica coluna.
 - Argumentos:
 - * Nova coluna que vai receber os dados unidos.
 - * Colunas originais que vão ceder os dados.
 - * Caracter separador usados para separar os dados na nova coluna.
 - Exemplo:


```
resposta_unida <- dados %>% unite("cor", c("cor1","cor2"), sep = ",")
```

- `complete()`
 - Gera todas as combinações possíveis entre as colunas, ou tabelas, selecionadas.
`dados %>% complete(coluna1,coluna2,coluna3,...)`
`dados %>% complete(dt1,dt2,...)`
 - Completa as combinações de colunas, se não houver valor, com **NA**.
 - O comando `nesting()`, que pode ser usado dentro da função `complete()`, cruza todos os valores de determinado grupo (tabela) com os pares únicos dos valores das colunas selecionadas em `nesting()`.
`dados1 %>% complete(dt,nesting(coluna1,coluna3))`
- `drop_na()`
 - Elimina as linhas, especificadas ou não, com valor **NA**.
 - Eliminando linhas com **NA**, de colunas especificadas:
`dados %>% drop_na(c(coluna1,coluna2))`
 - Eliminando todas as linhas com valor **NA**:
`dados %>% drop_na()`
- `replace_na()`
 - Substitui os valores **NA**, de determinada coluna, por outro valor especificado.
 - Especifica a coluna, ou as colunas através de `list()`, e define o valor caso **NA**.
 - Exemplo:
`dados %>% replace_na(list(paciente = "ausente", antes = 0, depois = 0))`

9 Cap 6 - Pacote data.table

9.1 Teoria

- Manipula dados, porém usa uma filosofia diferente de **tidyverse**.
- Chega nos mesmo resultados que **tidyverse**.
- Apresenta um ganho em desempenho no tempo, em relação ao **tidyverse**.
- Não necessita de tantos pacotes para executar as tarefas.

9.2 Estrutura

- A estrutura básica do `data.table`:
 - Sintaxe:
`DT[i,j,by]`
onde,
 - * **DT**
É o nome do `data.frame`.
 - * *i*
Corresponde a(s) linha(s) selecionadas, ou uma operação sobre a(s) linha(s).
 - * *j*
Corresponde a(s) coluna(s) selecionadas, ou uma operação sobre a(s) coluna(s).
 - * *by*
Agrupa os dados em torno de determinada(s) coluna(s) (semelhante a `group_by`).
 - Exemplo:
`dt[, .N, by = filial]`
Obs.: A função `.N` conta número de registros.
- O `data.table` pode receber mais argumentos (como no `magrittr`, semelhante ao operador *pipe*):
 - Sintaxe:
`DT[i,j,by][...]...`
 - Exemplo:
`DT[c(1,7,9)][order(-valor_compra)]`

9.3 Transformando data.frame em data.table

- Para transformar `data.frame` em `data.table` aplicamos a função `data.table()`.
- Exemplo:

Biblioteca

```
library(data.table)

# Transformando data.frame dados em data.table dt
dt <- data.table(dados)
```

9.4 data.table

9.4.1 Manipulando linhas

Table 13: 5 formas de manipulação de linhas no data.table

Comando	O que faz?
DT[condições sobre as colunas]	Seleciona as linhas de DT que satisfazem as condições.
DT[1:k]	Seleciona as linhas de 1 a k.
DT[order(j1,j2)]	Ordena os dados em ordem ascendente do vetor 1, seguido por vetor 2. Para ordem descendente use sinal de menos antes do nome do vetor. Ex.: DT[order(-j)]
unique(DT) ou unique(DT,by = colunas selecionadas)	Seleciona as linhas distintas (elimina as repetidas) considerando as colunas selecionadas.
na.omit(DT,cols = colunas selecionadas)	Elimina as linhas com valores faltantes, considerando as colunas selecionadas.

9.4.2 Manipulando colunas

Table 14: 8 formas de manipulação de colunas no data.table

Comando	O que faz?
DT[,j] ou DT[[j]]	Seleciona a coluna j e retorna um vetor.
DT[,list(j)] ou DT[,.(j)]	Seleciona a coluna j e retorna um data.table
DT[,-c(j1,j2,...,jn)]	Exclui as colunas listadas j1, j2, ..., jn
DT[,.(j1,j2,...,jn)]	Retorna as colunas listadas j1, j2, ..., jn
DT[,.(nome_escolhido = função(j))]	Aplica a função especificada à coluna j e retorna um data.table.
DT[,.(nome_1 = f(j1), nome_2 = f(j2), ..., nome_n = f(jn))]	Aplica várias funções a várias colunas e retorna um data.table.
DT[,novacol := vetor]	Adiciona uma nova coluna.
DT[,c('col1', 'col2', ..., 'coln') := c(vetor1, vetor2, ..., vetorn)]	Adiciona várias novas colunas.

9.4.3 Sumarizando dados

- Realiza operações para apuração de valores sobre linhas de um `data.table`.
- Argumentos de operações de sumariazação de dados:

Table 15: Argumentos para operações em um DT aplicados a uma ou mais colunas

Comandos	O que faz?
<code>.N</code>	Conta o número de linhas.
<code>DT[, .N, by = c(j1, ..., jn)]</code>	Conta o número de linhas de acordo com os agrupamentos das colunas <code>j1, ..., jn</code>
<code>DT[, (f1(j1), ..., fn(jn)), by = j]</code>	Aplica diversas funções nas colunas especificadas, de acordo com o agrupamento da coluna <code>j</code> em <code>by</code> .
<code>DT[, (f1(j1), ..., fn(jn)), keyby = .(j1, ..., jn)]</code>	Aplica diversas funções nas colunas especificadas, de acordo com o agrupamento das colunas listadas <code>j1, ..., jn</code> em <code>keyby</code> .

9.4.4 Operando um subconjunto de dados

- O pacote possui um símbolo especial denotado por `.SD` para realizar operações em um subconjunto de dados do `data.table` **DT**, de acordo com um grupo definido por `by` (agrupa em torno de determinadas colunas, igual a `group_by`).
 - `DT[, .SD]`
Subconjunto completo dos dados.
 - `DT[, .SD, by = .(j)]`
É o subconjunto completo dos dados exeto pela coluna `j`, formando subconjuntos para cada grupo da coluna `j`.
 - `DT[, .SD, by = .(j,k)]`
Podemos agrupar entorno de mais de uma coluna, definidas por `by`.
- É possível ainda definir (**selecionar**) as colunas do conjunto completo que deverão ser consideradas em `.SD` através do operador `.SDcols`. São as colunas que vão receber as funções.
`DT[, lapply(.SD, mean), .SDcols = c("coluna_1", "coluna_2"), by = .(coluna_3)]`
- `lapply`
 - Aplica a função determinada no subconjunto.
Sintaxe: `lapply(.SD, função)`
 - É comum que apareça dentro de `data.table` quando realizando operação de subconjuntos. É fundamental para as operações.
Ex.: `DT[, lapply(.SD, mean), .SDcols = "coluna_1", by = .(coluna_2)]`
 - Podem ser aplicadas várias funções no subconjunto.
Ex.: `DT[, c(lapply(.SD, mean), lapply(.SD, sum)), .SDcols = "coluna_1", by = .(coluna_2)]`
- Exemplo:
`DT[, c(lapply(.SD, mean), lapply(.SD, sum)), .SDcols = c("coluna_1", "coluna_2"), by = .(coluna_3, coluna_4)]`
 - Aplica as funções média(`mean`) e soma(`sum`) sobre as colunas selecionadas `coluna_1` e `coluna_2`.
 - Agrupando os dados (`by`) entorno das colunas selecionadas `coluna_3` e `coluna_4`.

9.4.5 Modificando dados com set

- As funções **set** são para modificação de dados do **data.table**.
- São as principais funções **set**:

Table 16: Funções set para modificação de dados no formato **data.table**

Funções set	Descrição	Fórmula
set	Modifica o valor da linha e coluna.	set(dt, i=1, j=3, value=999)
setnames	Modifica o nome da coluna.	setnames(dt, old='nome_coluna', new='novo_nome_coluna')
setorder	Reordena linhas de forma decrescente ou crescente.	setorder(dt, -vendas, n_itens)
setcolorder	Reordena colunas.	setcolorder(dt, c(1,3,2))

10 Cap 7 - Gráficos pacote básico e pacote ggplot2

- Objetivo é obter o gráfico ideal, com o qual se consiga visualizar os dados e analisá-los.
- Os principais passos:
 - Identificação dos tipos de variáveis.
 - Construção dos gráficos.
 - Ajustes.
 - Refinamento.

10.1 Gráficos com o pacote básico

- Principais funções de gráfico do pacote básico:

Table 17: Nome das principais funções para construção de gráficos do pacote base.

Função	Tipo de Gráfico
<code>barplot(x)</code>	Produce um gráfico de colunas do vetor <code>x</code> .
<code>boxplot(x)</code>	Produce o boxplot de <code>x</code> .
<code>coplot(y~x z)</code>	Produce um gráfico de dispersão entre <code>x</code> e <code>y</code> condicionado por <code>z</code> .
<code>curve(expressão)</code>	Produce um gráfico a partir da expressão de certa função de <code>x</code> .
<code>dotplot(x)</code>	Produce um gráfico de pontos.
<code>hist(x)</code>	Produce um histograma do vetor <code>x</code> .
<code>mosaicplot</code>	Produce um mosaico para tabelas de contingência.
<code>pairs(x)</code>	Produce uma grande de gráficos de dispersão entre variáveis quantitativas de uma tabela.
<code>pie(x)</code>	Produce um gráfico circular (pizza).
<code>plot(x)</code>	Produce um gráfico de dispersão entre <code>x</code> e <code>y</code> .
<code>qqnorm(x)</code>	Plota os quantis de <code>x</code> usando como base a curva normal.
<code>stem(x)</code>	Produce um ramo e folha.
<code>stripchart</code>	Produce um gráfico de dispersão unidimensional.

- Principais argumentos das funções de gráfico do pacote básico:

Table 18: Nome dos argumentos para adicionar efeito em gráficos.

Função	Efeito no gráfico
adj=	Controla a formatação do texto (0 formatação à esquerda; 0.5 centralizada; 1 à direita).
main=	Adiciona um título principal ao gráfico de acordo com texto entre aspas.
col=	Comando para colorir diversos itens do gráfico, pode ser valores como 1,2,..., ou por nome como 'red', 'blue', etc (consulte nomes com o comando colors() ou sistemas como rgb(), hsv(), gray() e rainbow()). Para cor das fontes use: col.lab, col.main, col.sub
border=	Especifica a cor da borda de uma coluna no gráfico.
font=	Controla o estilo da fonte de: 0-normal, 1-italico, 2-negrito, 3-italico e negrito.
cex=	Controla o tamanho da fonte de textos, o valor padrão é 1.(cex.axis, cex.lab, cex.main, cex.sub)
lty=	Especifica o tipo de linha (1-sólida, 2-tracejadas, etc).
lwd=	Especifica a espessura da linha (1, 2, ...).
pch=	Controla o tipo de símbolo (1 a 25 ou especificando entre aspas).
type=	Especifica o tipo de plotagem: 'p' (pontos); 'l' (linhas); 'b' (pontos conectados por linhas); 'o' (idem a b com pontos sobrepostos à linhas); 'h' (linhas verticais); 's' (degrau no qual o dado é representado no topo da linha vertical); 'S' (idem ao s porém o dado é representado na base da linha vertical).
xlim=(inicio,fim)	Controla os limites do eixo X.
ylim=(inicio,fim)	Controla os limites do eixo Y.
xlab=	Adiciona rótulo para o eixo X de acordo com texto entre aspas.
ylab=	Adiciona rótulo para o eixo Y de acordo com texto entre aspas.
las=	Controla a orientação dos rótulos dos eixos. 0 - paralelo ao eixo; 1 - horizontal; 2 - perpendicular; 3 - vertical.
xaxt ou yaxt=	Se xaxt = 'n', o eixo X é definido porém não é desenhado; Se yaxt = 'n', o eixo Y é definido porém não é desenhado.
text	
(x,y,'texto',cex,col)	Adiciona texto ao gráfico na coordenada (x,y) podendo ser diminuído o tamanho da fonte na proporção desejada em relação ao tamanho padrão 1 e com a cor especificada.
legend(x,y,legenda)	Adiciona uma legenda no ponto (x,y) com símbolos dados no campo legenda
locator	
(n,type='n',...)	Retorna as coordenadas correspondentes pedidas pelo usuário ao clicar (n vezes) no gráfico. Também desenha símbolos (type = 'p') ou linhas (type = 'l') Respeitando os parâmetros do gráfico. Por padrão type = 'n'.
segments(x0,y0,x1,y1)	Desenha segmentos de linha a partir do ponto (x0,y0) até (x1,y1).

- Observações sobre visualização:
Podemos usar o comando `par(mfrow = c(i,j))` que prepara uma janela gráfica para receber vários gráficos.
 - Dois gráficos, lado a lado.
`par(mfrow=c(1,2))`
 - Dois gráficos, um abaixo do outro.
`par(mfrow=c(2,1))`
 - Quatro gráficos, sendo dois em cada linha.
`par(mfrow=c(2,2))`
 - Um gráfico na janela gráfica.
Basta omitir o comando.
 - Redefinir o número de linhas a partir das margens da janela gráfica (**default**).
`par(mar=c(5,4,4,2))`
Sendo na ordem: abaixo, esquerda, acima e direita.
Esses valores tem impacto no espaço dos títulos dos gráficos.
Mudar esses valores reajusta o gráfico.
 - Define a medida das margens.
`par(mai=c(x1,x2,x3,x4))`
Sendo na ordem: abaixo, esquerda, acima e direita.
 - Fecha a janela gráfica (*devices*).
`dev.off()`

10.1.1 Gráfico de barras (barplot)

- A função `barplot()` gera um gráfico de barras.

10.1.1.1 Pré-requisitos

- Necessita que os dados estejam preparados para gerar os gráfico, em formato *tabulado*.
- Para preparação dos dados é necessario o uso das funções dos pacotes `magrittr`, `dplyr` (ou `data.table`), e `tidyr`.
- Uma coluna com os dados **númericos** (frequencias e/ou valores).
- Uma coluna com os dados **string**, ou **factor**.

10.1.1.2 Preparação dos dados

- Organização dos dados das colunas, colocando uma coluna em função da outra. As principais funções nesse caso são:
 - **order**
Retorna uma permutação que reorganiza seu primeiro argumento em ordem crescente ou decrescente, quebrando laços por argumentos adicionais.
`x <- tabula_Estado$Estado[order(tabula_Estado$cheg_2012)]`
 - **sort**
Ordena um vetor em ordem crescente ou decrescente.
`y <- sort(tabula_Estado$cheg_2012)/1000`
- Definindo parâmetros para a janela gráfica (**par**):
 - **mar**
Vetor numérico que oferece o número de linhas a partir das margens da janela gráfica.
No formato `c(inferior, esquerda, superior, direita)`.
`mar = c(9,5,4,2)`
 - **mai**
Vetor numérico que oferece o tamanho da margem, especificado em polegadas.
No formato `c(inferior, esquerda, superior, direita)`.
`mai = c(1.8,1,0.8,0.4)`
 - Exemplo:
`par(mar = c(9,5,4,2),mai = c(1.8,1,0.8,0.4))`

10.1.1.3 Plotagem gráfico de barras (barplot)

- Principais argumentos:

- `y`
Vetor do eixo Y.
- `names.arg`
Vetor com os nomes das barras do eixo X.
- `main`
Título principal do gráfico.
- `cex.main`
Tamanho da fonte de textos (título do gráfico).
- `xlab`
Rótulo do eixo X.
- `ylab`
Rótulo do eixo Y.
- `cex.names`
Tamanho da fonte de textos (nomes das barras do eixo X, vetor `x`).
- `axisnames`
Inclui os nomes das categorias no eixo `x`.
- `las`
Controla a orientação dos rótulos dos eixos.
- `ylim`
Controla os limites do eixo Y.
- `text`
Neste caso, adiciona valores de Y no topo de cada barra de `xbar` (variável com gráfico).
Como consequência dessa função, é necessário colocar o gráfico dentro de uma variável (`xbar`), se não for desejado este artifício não é necessário colocar `barplot` dentro de uma variável.
- Para plotar gráfico de barras na horizontal basta adicionar o argumento `horizon = TRUE`.
- Exemplo:

```
xbar = barplot(  
y, names.arg = x,  
main = "Título do gráfico.",  
cex.main = 1.5,  
xlab = "Rótulo do eixo X.",  
ylab = "Rótulo do eixo Y.",  
cex.names = 1,  
axisnames = T,  
las = 2,  
ylim = c(0,1.2*max(y))  
)
```

```
text(xbar, y, label = round(y,2), pos = 3, cex = 0.8, col = "black")
```



Figure 4: Gráfico de barras - Vertical




Figure 5: Gráfico de barras - Horizontal

10.1.2 Gráfico circular/pizza (pie)

- A função `pie` gera um gráfico circular/pizza.
- Essa forma de visualização serve para analisar a frequência de variáveis categóricas.

10.1.2.1 Pré-requisitos

- Utilize somente em casos de a variável possuir poucas categorias (em torno de cinco).
- Com quantidades diferentes entre si.
- Caso não se enquadrar nos pré-requisitos o ideal é optar por gráfico de barras.
- Os dados devem estar organizados em formato tabular.

10.1.2.2 Preparação dos dados

- Organização dos dados das colunas, colocando uma coluna em função da outra. As principais funções nesse caso são:
 - `order`
Retorna uma permutação que reorganiza seu primeiro argumento em ordem crescente ou decrescente, quebrando laços por argumentos adicionais.
`x <- tabula_Estado$Estado[order(tabula_Estado$cheg_2012)]`
 - `sort`
Ordena um vetor em ordem crescente ou decrescente.
`y <- sort(tabula_Estado$cheg_2012)/1000`
- Definindo parâmetros para a janela gráfica (`par`):
 - `mar`
Vetor numérico que oferece o número de linhas a partir das margens da janela gráfica. No formato `c(inferior, esquerda, superior, direita)`.
`mar = c(9,5,4,2)`
 - `mai`
Vetor numérico que oferece o tamanho da margem, especificado em polegadas. No formato `c(inferior, esquerda, superior, direita)`.
`mai = c(1.8,1,0.8,0.4)`
 - Exemplo:
`par(mar = c(9,5,4,2),mai = c(1.8,1,0.8,0.4))`

10.1.2.3 Plotagem gráfico circular/pizza (pie)

- Principais argumentos:

- **y**
O vetor do eixo Y, contendo os valores das categorias.
- **main**
Título principal do gráfico.
- **labels**
Rótulo com cada categoria do gráfico.
- **cex.main**
Tamanho da fonte de textos (título do gráfico).
- **cex**
Tamanho do texto dos rótulos (**labels**).
- **col**
Comando para colorir diversos itens do gráfico, pode ser valores como 1,2,..., ou por nome como 'red', 'blue', etc.
Neste caso para colorir os pedaços do gráfico circular/pizza.
- **text**
Adiciona texto ao final do gráfico, neste caso o texto é a fonte usada para elaboração do gráfico.
Dentro do **text** apresenta parâmetros para localizar o texto na janela gráfica, o texto e tamanho da fonte.
- **rotulos**
Variável que recebe o texto, a partir da função **paste** de concatenação de texto e valores, com os rótulos de cada categoria, contendo nome de cada categoria (**x**) e porcentagem(**porc**).
- Exemplo:


```
#Juntando categorias com baixa proporção na categoria outros.  
y <- c(sum(y[1:10]), y[11:15])  
x <- c("Outros", as.character(x[11:15]))
```

```
#Gráfico circular/pizza  
#Variável rótulo  
porc = 100*round(y/sum(y),2) #calcula a %  
rotulos = paste(x,"(",porc,"%)",sep = "") #texto para rotulo
```

```
#plotando gráfico pizza  
par(mar = c(4,0,2,0), mai = c(0.8,0,0.4,0))  
pie(  
y,  
main = "Título do gráfico",  
labels = rotulos,  
cex.main = 2,  
cex = 1.5,  
col = gray(1:length(x)/length(x))  
)
```

```
text(0, -1, "Fonte: Elaborado com pacote graphics version 3.6.1 do R.", cex = 1)
```

Proporção de chegadas de turistas por Estado em 2012



Fonte: Elaborado com pacote graphics version 3.6.1 do R.

Figure 6: Gráfico circular/pizza

10.1.3 Gráfico de linhas (plot lines)

- O gráfico de linhas (`plot`) é utilizado para visualizar uma ou mais variáveis numéricas que podem ser plotadas ao longo do tempo (não somente tempo) no eixo x.
- Podemos adicionar mais linhas (variáveis) no gráfico através do comando `lines`.

10.1.3.1 Pré-requisitos

- Os dados devem estar organizados em formato tabular.

```
dados_SP <- dados %>%  
  select(Mes, Estado, cheg_2012, cheg_2013, cheg_2014, cheg_2015) %>%  
  filter(Estado == "SaoPaulo")  
dados_SP
```

- Separar as colunas em vetores.

```
# Definindo os valores dos eixos  
x <- dados_SP$Mes  
y1 <- dados_SP$cheg_2012/1000  
y2 <- dados_SP$cheg_2013/1000  
y3 <- dados_SP$cheg_2014/1000  
y4 <- dados_SP$cheg_2015/1000
```

10.1.3.2 Preparação dos dados

- Definir os limites do eixo y:
 - **li**
Variável que recebe o limite inferior do eixo y, com base no menor valor do eixo y dos vetores de cada coluna.
 - **ls**
Variável que recebe o limite superior do eixo y, com base no maior valor do eixo y dos vetores de cada coluna.
 - Exemplo:

```
# Definindo os limites do eixo y  
li <- min(y1,y2,y3,y4)  
ls <- max(y1,y2,y3,y4)
```

10.1.3.3 Plotagem gráfico `plot`

- Principais argumentos:
 - **x**
Variável do tipo vetor que recebe valores de tempo.
 - **y1, y2, y3 e y4**
Variáveis do tipo vetor em que cada uma representa os valores de uma linha.
 - **lty**
Especifica o tipo de linha.
 - **lwd**
Especifica a espessura da linha.
 - **type**
Especifica o tipo de plotagem, 'b' (pontos conectados por linhas).
 - **ylim**
Controla os limites do eixo Y.
 - **xlab**
Rótulo do eixo X.
Quando o gráfico apresentar diversas linhas, o rótulo deve ser inicializado e zerado dentro do `plot` e adicionado seu valor definitivo na função `title`.
 - **ylab**
Rótulo do eixo Y.
Quando o gráfico apresentar diversas linhas, o rótulo deve ser inicializado e zerado dentro do `plot` e adicionado seu valor definitivo na função `title`.
 - **lines**
Adiciona novas linhas ao gráfico de linhas, cada uma com suas particularidades.
 - **title**
Função que adiciona títulos, rótulos e texto ao gráfico de linhas.
 - **main**
Título principal do gráfico.
 - **sub**
Adiciona texto ao final do gráfico.
 - **cex.sub**
Tamanho da fonte do texto.
 - **col**
Comando para colorir diversos itens do gráfico, pode ser valores como 1,2,..., ou por nome como 'red', 'blue', etc.
Neste caso para colorir as linhas do gráfico de linhas.
 - **legend**
Adiciona um quadro de legenda a janela gráfica.

– Exemplo:

```
plot(x, y1, lty = 1, lwd = 1, type = "b", ylim = c(0.8*li,ls*1.2),xlab = "",
     ylab = "", col = "red")
lines(x, y2, lty = 2, lwd = 1, type = "b", col = "yellow")
lines(x, y3, lty = 3, lwd = 2, type = "b", col = "blue")
lines(x, y4, lty = 4, lwd = 1, type = "b", col = "green")
title(main = "Chegada de turistas em São Paulo",
      xlab = "Mês",
      ylab = "Chegadas por mil",
      sub = "Fonte: Elaborado com pacote graphics version 3.6.1 do R.",
      cex.sub = 0.8)
legend(9,400,c("2012","2013","2014","2015"), col = c("red","yellow","blue","green"),
      lty = 1:4, cex = 0.5)
```



Figure 7: Gráfico de linhas

10.1.3.4 Comparando séries de gráficos de linhas

10.1.3.4.1 O que é comparar séries

- O intuito é plotar mais de um gráfico na mesma janela gráfica, para facilitar a comparação das diferentes séries de dados.
- Sendo possível preparar a janela gráfica assim como uma matriz, para receber gráficos em linha, ou em coluna, ou em linhas e colunas ao mesmo tempo.

10.1.3.4.2 Preparação da janela gráfica

- Existem duas formas de preparar a janela gráfica para receber os gráficos:
 - `par(mfrow = c(nº_linhas, nº_colunas))`
Prepara a janela gráfica como uma matriz, sendo definido o número de linhas e colunas a receber os gráficos.
Necessita ajustar os parâmetros de margem da janela gráfica(`mai` e `mar`), por conta disto não é o mais aconselhado de usar.
 - `layout(matrix(nº_linhas,nº_colunas), nº_linhas, nº_colunas)`
Prepara a janela gráfica como uma matriz, sendo definido o número de linhas e colunas a receber os gráficos.
Mais recomendado a utilização.

10.1.3.4.3 Plotagem de gráficos de linhas comparando séries

#script para dois graficos de linha

#preparando a janela grafica para receber dois graficos

#metodo 1 - não recomendado

#par(mfrow = c(2,1)) #necessidade de configurar margens

#par(mar = c(6,4,1,1), mai = c(0.9,0.9,0.3,0.1))

#Metodo 2 - Recomendado

layout(matrix(c(1,2), 1, 2)) #tende a funcionar melhor que par(mfrow())

#numero de linhas, numero de colunas

#grafico 1

#definindo os limites do eixo y

li1 <- min(y1,y2,y3,y4)

ls1 <- max(y1,y2,y3,y4)

#script para o grafico de linha

plot(x1, y1, lty = 1, lwd = 1, type = "b", ylim = c(0.8*li1,ls1*1.2),xlab = "",

ylab = "") #xlab e ylab vazios some com os rotulos x e y, para que possa colocar a no titulo (titl

lines(x1, y2, lty = 2, lwd = 1, type = "b") #acrescenta y2

lines(x1, y3, lty = 3, lwd = 2, type = "b") #acrescenta y3

lines(x1, y4, lty = 4, lwd = 1, type = "b") #acrescenta y4

#lty = especifica o tipo de linha

#lwd = especifica a espessura da linha

#type = especifica o tipo de plotagem, 'b' (pontos conectados por linhas)

```

title(main = "Chegada de turistas em São Paulo",
      xlab = "Mês",
      ylab = "Chegadas por mil")
legend(9,400,c("2012","2013","2014","2015"), lty = 1:4, cex = 0.5) #os dois primeiros valores são a pos

#grafico 2

#definindo os limites do eixo y
li2 <- min(z1,z2,z3,z4)
ls2 <- max(z1,z2,z3,z4)

#script para o grafico de linha
plot(x2, z1, lty = 1, lwd = 1, type = "b", ylim = c(0.8*li2,ls2*1.2), xlab = "",
     ylab = "") #xlab e ylab vazios some com os rotulos x e y, para que possa colocar a no titulo (
lines(x2, z2, lty = 2, lwd = 1, type = "b") #acrescenta y2
lines(x2, z3, lty = 3, lwd = 2, type = "b") #acrescenta y3
lines(x2, z4, lty = 4, lwd = 1, type = "b") #acrescenta y4
#lty = especifica o tipo de linha
#lwd = especifica a espessura da linha
#type = especifica o tipo de plotagem, 'b' (pontos conectados por linhas)
title(main = "Chegada de turistas em Rio de Janeiro",
      xlab = "Mês",
      ylab = "Chegadas por mil",
      sub = "Fonte: Elaborado com pacote graphics version 3.6.1 do R.", cex.sub = 0.8)
legend(9,300,c("2012","2013","2014","2015"), lty = 1:4, cex = 0.5) #os dois primeiros valores são a pos

```




Figure 8: Gráfico de linha comparando séries

10.1.4 Gráfico de dispersão (plot abline)

- O gráfico de dispersão é usado para observar a relação entre duas variáveis quantitativas (que podem ser contadas).
- O pesquisador a princípio busca uma relação linear, logo a visão do gráfico deve ser acompanhado do **coeficiente de correlação linear**, que mede matematicamente a intensidade dessa relação.
- **Coeficiente de correlação linear:**
 - A relação entre duas variáveis é chamada **regressão linear simples**.
 - O coeficiente de **correlação linear** é uma medida que varia entre 1 e -1.
 - Espera-se encontrar valores próximos de -1 e 1 no caso de presença de relacionamento linear.
 - no caso de 1.
O coeficiente é positivo ou dito crescente, uma variável cresce acompanhando o crescimento da outra.
 - no caso de -1.
O coeficiente é negativo ou dito decrescente, uma variável cresce com o decaimento da outra.

10.1.4.1 Pré-requisitos

- Os dados devem estar em formato tabular, ou as variáveis em formato de vetor.

10.1.4.2 Preparação dos dados

- Coeficiente de Correlação linear:
 - Teoria
 - * O coeficiente de correlação tem o objetivo de entender como uma variável se comporta num cenário onde a outra variável varia. E se existe alguma relação entre a variabilidade de ambas as variáveis.
 - * Os coeficientes variam de 1 a -1. Quanto mais próximo dos extremos, mais forte é a relação entre as variáveis. Quanto mais próximo do centro 0, menor é a relação entre as variáveis. Em 0 não existe relação entre as variáveis.
 - * A correlação próximo do valor 1, significa que a relação é positiva, ou seja, a reta de regressão é ascendente. Quando uma variável aumenta a outra aumenta também.
 - * A correlação próximo do valor -1, significa que a relação é Negativa, ou seja, a reta de regressão é descendente. Quando uma variável diminui a outra aumenta.
 - Cálculo de correlação linear:

$$cor_{x,y} = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{\sqrt{n \sum x_i^2 - (\sum x_i)^2} \cdot \sqrt{n \sum y_i^2 - (\sum y_i)^2}}$$




Figure 9: Correlações fortes e fracas




Figure 10: Tipos de Correlação

Onde,
 n é o número de registros/linhas.
 x_i é o vetor x .
 y_i é o vetor y .
 xy é x vezes y .

Uma forma rápida e simples de resolver o cálculo é preencher a tabela de correlação linear com as informações:

	x	y	xy	x^2	y^2
n					
Σ					

Figure 11: Tabela de correlação linear

– `cor(x,y)`

Função do **R** que calcula a correlação linear das variáveis vetor x e y .

- Coeficiente de reta de regressão:

Tenta traçar uma reta que melhor aproxime todos os pontos dispersos.

$$y = A + Bx$$

Onde,

A é o intercepto

B é o coeficiente angular.

– Coeficiente angular:

$$B = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}$$

– Intercepto:

$$A = \frac{\sum y - B \sum x}{n}$$

– `lm(y ~ x)$coef`

Esta função do **R** retorna os coeficientes da reta de regressão (**intercepto** e **coeficiente angular**).

A parte da função `$coef` apenas retorna de maneira mais direta os coeficientes separados, assim deixando claro em cada coluna o que é **intercepto** e o que é **coeficiente angular**.

10.1.4.3 Plotagem gráfico plot abline

- Funções usadas:
 - `paste()`
Concatena as strings e valores.
 - `expression()`
Salva numa variável o desenho de texto no formato **expression**, ou seja, uma expressão matemática, uma equação.
As Expressões (**expressions**) podem ser usadas como título, subtítulo e rótulos de eixos.
 - `eval()`
Avalia, e se possível resolve, uma **expression**.
- Principais argumentos do gráfico de dispersão:
 - **x**
Vetor com variável quantitativa x.
 - **y**
Vetor com variável quantitativa y.
 - **main**
Título principal do gráfico.
 - **xlab**
Rótulo do eixo x.
 - **ylab**
Rótulo do eixo y.
 - **text**
Adiciona texto ao gráfico.
Neste caso adiciona, pela posição do texto inserido, o nome a reta e a equação/expressão da reta.
 - **abline**
Adiciona a reta tracejada.
 - **lty**
Especifica o tipo de linha.
 - **lwd**
Especifica a espessura da linha.
 - Exemplo:

```
#Observando a correlação entre as chegadas de São Paulo e Rio de Janeiro
x <- dados_RJ$cheg_2014/1000
y <- dados_SP$cheg_2014/1000
x
y

#Obtendo a correlação
```

```

cor(x,y)

#Obtendo os coeficientes da reta de regressão
lm(y ~ x)$coef
#lm = é usado para ajustar modelos lineares. Ele pode ser usado para realizar regressão, análise de
#coef = é uma função genérica que extrai coeficientes de modelo de objetos retornados por funções c

#Gráfico de dispersão
plot(x, y,
     main = paste("Gráfico de Dispersão entre as chegadas de turistas de 2014",
                  "\n", "São Paulo x Rio de Janeiro"),
     xlab = "Chegadas no Rio de Janeiro/1000",
     ylab = "Chegadas em São Paulo/1000"
    )
abline(lm(y ~ x), lty = 2, lwd = 2) #adiciona a reta tracejada
#lty = especifica o tipo de linha
#lwd = especifica a espessura da linha
text(130,230,"reta de regressão") #adiciona texto na posição (130,230)
text(130,210,paste("y = ",eval(expression(round(lm(y ~ x)$coef[[2]],2))),
                  #[[j]] seleciona a coluna j.
                  "x + ",eval(expression(round(lm(y ~ x)$coef[[1]],2)))))
#adiciona equação na posição (130,210)
#paste = Concatenar vetores após a conversão em caractere.
#eval = Avalie uma expressão R em um ambiente especificado.
#expression = Cria ou testa objetos do modo "expressão".

```




Figure 12: Gráfico de dispersão

10.1.5 Diagrama de caixa (boxplot)

- O **Diagrama de caixa** serve para compreensão da forma e amplitude dos dados.
- É importante para fazer o **diagrama de caixa** conhecer a fórmula das **separatrizes**.
- O **diagrama de caixa** usa em sua construção os conceitos de **quartis** (**Q1**, **Q2**, e **Q3**).

10.1.5.1 Separatrizes

- Quartis:
 - Q1 (25%)
 - Q2 (50% ou mediana)
 - Q3 (75%)
- Tabela de distribuição de frequências:

Salário	<i>N.º de prof.</i> <i>(fi)</i>	<i>fac</i>
01 --- 03	20	20
03 --- 05	40	60
05 --- 07	60	120
07 --- 09	30	150
09 --- 11	10	160
Total	160	-----

Figure 13: Exemplo de tabela de distribuição de frequências

- Como achar o intervalo de classe que corresponde a separatriz calculada.
Ex.: Se Q1 (25%), achar na tabela de classes e frequências, na coluna frequência acumulada, a classe que contém o valor que corresponde a 25% da frequência acumulada total.
Esse intervalo de classe será a classe selecionada para aplicação da fórmula.

- Fórmula da separatriz:

$$P_k = Li + \frac{k \cdot \sum f_i - F_{anterior}}{f_{intervalo}} \cdot h$$

onde,

P_k é o percentil (separatriz),

Li é o limite inferior do intervalo de classe selecionada,

k é o número em fração do percentil,

f_i é a frequência,

$\sum f_i$ é a frequência acumulada total,

$F_{anterior}$ é a frequência acumulada do intervalo de classe anterior (ao selecionado) do qual se está calculando,

$f_{intervalo}$ é a frequência do intervalo de classe selecionada,

h é a amplitude de classe ($Ls - Li$).

10.1.5.2 boxplot

- Montando a box:

A box contém como limite superior Q_3 , limite inferior Q_1 e linha interna a mediana (Q_2).

- Intervalo interquartil:

$$IQR = Q_3 - Q_1$$

- Limites:

– Máximo

$$L_{máx} = Q_3 + 1,5 \cdot (IQR)$$

– Mínimo

$$L_{mín} = Q_1 - 1,5 \cdot (IQR)$$

- Valores discrepantes (**Outliers**):

– Possíveis erros (arredondamento ou observação).

– Alguma condição especial que deve ser observada separadamente.

- Exemplo explicativo de boxplot:




Figure 14: Exemplo explicativo de boxplot

10.1.5.3 Pré-requisitos

- Os dados devem estar em formato tabular.

10.1.5.4 Preparação dos dados

- A variável em formato de vetor.
Ex.: `x <- turismo$cheg_2012/1000`

10.1.5.5 Plotagem gráfico boxplot

- Principais argumentos do gráfico de dispersão:

- **x**
Variável em formato de vetor.
- **main**
Título principal do gráfico.
- **xlab**
Rótulo do eixo x.
- **ylab**
Rótulo do eixo y.
- Exemplo:

```
#Variável x
x <- turismo$cheg_2012/1000

#Plotando o diagrama de caixa - boxplot
boxplot(x,
  main = "Boxplot das chegadas de Turistas ao Brasil em 2012",
  xlab = "Ano de 2012",
  ylab = "Chegadas de turistas em 2012 por mil")
```




Figure 15: Gráfico de caixa (boxplot)

10.1.6 histograma (hist)

- Histograma é um tipo de gráficos de barras.
- É usado para variáveis quantitativas contínuas.
- Este tipo de gráfico é muito usado para observar:
 - **Distribuição de frequências**
 - **Simetria**
 - **Desvio**
Presença de valores discrepantes (Outliers).
 - **Amplitude da variável**
- A diferença entre gráficos de barras e histograma:
 - **Gráfico de barras**
É aplicado a variáveis categóricas, apenas um eixo representando variável numérica e o outro eixo representando um variável categórica.




Figure 16: Exemplo gráfico de barras

- **Histograma**
É aplicado a variáveis numéricas e possui dois eixos numéricos (x representando a variável e y representando a frequência da variável).




Figure 17: Exemplo histograma

10.1.6.1 Pré-requisitos

- Os dados devem estar em formato tabular.

10.1.6.2 Preparação dos dados

- A variável em formato de vetor.
Ex.: `x <- dados$cheg_2012/1000`
- A frequência é calculada automaticamente pela função `hist` (histograma), basta informar a função se ela deve calcular a frequência absoluta (**T**) ou a frequência relativa (**F**).
Ex.: `hist(... , freq = T | F, ...)`

10.1.6.3 Plotagem gráfico boxplot

- Principais argumentos do histograma:
 - **x**
Variável em formato de vetor.
 - **freq**
É a frequência.
Caso queira a frequência absoluta = **T**.
Caso queira a frequência relativa = **F**.
 - **col**
Comando para colorir diversos itens do gráfico, pode ser valores como 1,2,..., ou por nome como 'red', 'blue', etc.
 - **main**
Título principal do gráfico.
 - **xlab**
Rótulo do eixo x.
 - **ylab**
Rótulo do eixo y.
 - **sub**
Adiciona texto ao final do gráfico.
 - Exemplo:

```
#Compreendendo a distribuição frequência de chegadas de turistas do Brasil em
#2012
x <- dados$cheg_2012/1000

#histograma
hist(x,
     freq = T, #se T fornece a frequencia absoluta, se F fornece a frequencia relativa
     main = "Histograma das chegadas de turistas ao Brasil em 2012",
     xlab = "Chegadas de turistas em 2012 por mil",
     ylab = "Frequencia Absoluta das chegadas",
```

```
sub = "Fonte: elaboração própria") #legenda
```




Figure 18: Histograma

10.2 Pacote ggplot2

O pacote **ggplot2** constroi diversos tipos de graficos a partir da mesma estrutura de componentes:

- **data**: referente ao banco de dados.
- **geom_forma**: um rol de tipos possiveis de representação dos dados.
- **coord_system**: referente ao sistema de coordenadas, que podem ser cartesianas, polares e projeção de mapas.

10.2.1 O que precisa para fazer o gráfico?

A. Um nome de objeto para guardar o grafico (uma variavel).

B. A base de dados que será utilizada para a plotagem.

`ggplot(data=nome_da_base)`

C. Descrever como as variaveis serão utilizadas na plotagem:

`aes(x=..., y=..., ...)`

D. Especificar o tipo de gráfico:

`geom_forma(...)`

E. Utilizar o operador “+” para adicionar camadas (*layers*) ao objeto **ggplot** criado.

F. Pacotes auxiliares como **ggthemes** e **grid**, dentre outros.

10.2.2 Quais formatos podemos utilizar no ggplot2 (*geom_forma*)?

Table 19: Nome das principais formas geométricas para construção de gráficos do pacote ggplot2

Forma	Tipo de gráfico
<code>geom_area</code> ou <code>geom_ribbon</code>	Produce um grafico para visualizar área sob a curva ou entre curvas.
<code>geom_bar</code> ou <code>geom_col</code>	Produce um grafico de colunas do vetor x.
<code>geom_bar+coord_polar</code>	Produce um grafico circular (Pizza).
<code>geom_boxplot</code>	Produce o boxplot de x.
<code>geom_curve</code>	Produce um grafico em curva.
<code>geom_density</code>	Produce um grafico da densidade de x.
<code>geom_dotplot</code>	Produce um grafico de pontos.
<code>geom_histogram</code>	Produce um histograma do vetor x.
<code>geom_line</code> , <code>geom_abline</code> , <code>geom_hline</code> , <code>geom_vline</code>	Produce um grafico de linhas
<code>geom_point</code>	Produce um grafico de dispersão entre x e y.
<code>geom_qq</code> ou <code>geom_qq_line</code>	plota os quantis de x usando como base a curva normal.
<code>geom_tile</code> , <code>geom_rect</code> ou <code>geom_raster</code>	Produce uma grade de retangulos.
<code>geom_violin</code>	Produce um grafico em forma de violino.

10.2.3 Nome dos argumentos para adicionar efeito em gráficos do pacote ggplot2

Table 20: Nome dos argumentos para adicionar efeito em gráficos do pacote ggplot2.

Funções	Efeitos no gráfico
<code>autoplot</code>	Produz um grafico apropriado para o tipo de variavel.
<code>coord_cartesian</code>	Coordenada cartesiana.
<code>coord_fixed</code>	Coordenada cartesiana com razão entre eixo x e y fixada.
<code>coord_flip</code>	Inverte a posição dos eixos x e y.
<code>coord_polar</code>	Coordenada polar.
<code>geom_blank</code>	Janela em branco.
<code>geom_jitter</code>	Produz um efeito jitter.
<code>geom_smooth</code>	Produz uma curva suavizada.
<code>geom_text</code>	Aplica texto a janela grafica.
<code>scale_fill_</code> (=brewer ou grey ou gradient)	Define a escala de cores.
<code>scale_*_contínuos</code>	Define parametros para o eixo x ou y contínuos.
<code>scale_*_discrete</code>	Define parametros para o eixo x ou y discreto.
<code>scale_*_manual</code>	Define parametros para os eixos manualmente.

10.2.4 Definindo um tema para o grafico ggplot

- *theme_gray*
Fundo cinza e linhas grandes brancas.
- *theme_bw*
O classico preto e branco. Otimo para projetor.
- *theme_linedraw*
Linhas pretasde varias larguras num fundo branco. semelhante ao theme_bw.
- *theme_light*
Semelhante ao theme_linedraw, porem com as linhas mais cinza claro, para dar atenção aos dados.
- *theme_dark*
Versão escura do theme_light, com o fundo escuro, util para criar linhas finas coloridas.
- *theme_minimal*
Um tema minimalista sem anotações de fundo.
- *theme_classic*
Tema classico, com linhas do eixo x e y, sem linhas de grade.
- *theme_void*
Um tema completamente vazio.

10.2.5 Pacote ggthemes

Table 21: Temas do pacote ggthemes

Tema	Semelhanças
theme_base	Tema do pacote básico do R
theme_calc	Semelhante aos gráficos produzidos pelo Calc do LibreOffice B
theme_economist	Semelhante ao The Economist
theme_economist_white	Semelhante ao The Economist com fundo branco
theme_excel	Semelhante aos gráficos produzidos pelo Excel
theme_few	Baseado nas regras de Stephen Few sobre regras práticas para o uso de cores nos gráficos
theme_fivethirtyeight	Baseado nos gráficos do site fivethirtyeight.com
theme_foundation	Tema de fundação, para produzir novos temas
theme_gdocs	Semelhante aos gráficos do Google Docs
theme_hc	Baseado em Highcharts JS
theme_igray	Inverte o tema gray
theme_map	Limpa o tema para incluir mapas
theme_pander	Baseado no pacote pander
theme_par	Baseado nos parâmetros definidos em par() do pacote base
theme_solarized	Baseado na paleta Solarized
theme_solarized_2	Baseado na paleta Solarized
theme_solid	Elimina todas as linhas e textos, mantendo somente os objetos geométricos
theme_stata	Semelhante aos gráficos do Stata
theme_tufte	Baseado no designer de Edward Tufte
theme_wsj	Semelhante aos gráficos do Wall Street Journal

Exemplo:

```
#Bibliotecas
library(ggthemes)

#Plotando gráficos
f <- ggplot(dados,aes(cheg_2012/1000,cheg_2013/1000)) +
  geom_blank() +
  labs(x="",y="")

#Tema
p1 <- f +
  theme_gdocs(base_size = 18) +
  ggtitle("theme_gdocs")

p1
```

10.2.6 Inserindo títulos, subtítulos e rótulos aos eixos de um ggplot

- Existem duas formas de inserir textos no gráfico no **ggplot2**.

10.2.6.1 Primeira forma

- Podemos adicionar texto ao gráfico **ggplot2** através do comando **labs()** e seus parâmetros:

- **title**
Adicionar um título ao gráfico **ggplot**.
- **x**
Adiciona um rótulo ao eixo x no gráfico **ggplot**.
- **y**
Adiciona um rótulo ao eixo y no gráfico **ggplot**.
- **subtitle**
Adicionar um subtítulo ao gráfico **ggplot**.
- **caption**
Adiciona texto ao final do gráfico **ggplot**.

- Exemplo:

```
#Plotando gráfico
p <- ggplot(data = Turismo, aes(x=cheg_2012/1000,y=cheg_2013/1000)) #Salva gráfico em variável

#Aplicando elementos de texto na forma janela em branco
p +
  geom_blank() + #Produz efeito janela em branco
  labs(title = "Título", #Adiciona texto ao gráfico
        x = "Eixo x", #Adiciona rótulo ao eixo x
        y = "Eixo y", #Adiciona rótulo ao eixo y
        subtitle = "Subtítulo", #Adiciona subtítulo ao gráfico
        caption = "Elaborado por ...")+ #Adiciona texto ao final do gráfico
  theme_bw(base_size = 18)
```

10.2.6.2 Segunda forma

- Podemos adicionar texto ao **ggplot2** através dos comandos:

- **ggtitle("", subtitle = "")**
O comando **ggtitle** adiciona título ao gráfico **ggplot**.
Podemos adicionar o parâmetro **subtitle** para adicionar um subtítulo ao gráfico **ggplot**.
- **xlab("")**
Adiciona um rótulo ao eixo x no gráfico **ggplot**.
- **ylab("")**
Adiciona um rótulo ao eixo y no gráfico **ggplot**.
- **labs(caption = "")**
O comando **labs()** acompanhado do parâmetro **caption**, adiciona texto ao final do gráfico **ggplot**.

- Exemplo:

```
#Plotando gráfico
p <- ggplot(data = Turismo, aes(x=cheg_2012/1000,y=cheg_2013/1000)) #Salva gráfico em variável

#Aplicando elementos de texto na forma janela em branco
p +
  geom_blank() + #Produce efeito janela em branco
  ggtitle("Título",subtitle = "Subtítulo") + #Adiciona título e subtítulo ao gráfico
  xlab("Eixo x") + #Adiciona rótulo ao eixo x
  ylab("Eixo y") + #Adiciona rótulo ao eixo y
  labs(caption = "Elaborado por ...") + #Adiciona texto ao final do gráfico
  theme_bw(base_size = 18)
```

10.2.7 Escalas no ggplot2

- Podemos definir a escala dos eixos utilizando uma camada específica para esse fim: `scale_x_discrete()` ou `scale_y_discrete()`
- Principais argumentos das funções `scale_x_discrete()` e `scale_y_discrete()`:
 - `drop`
T omite do gráfico os níveis de um fator que não aparecem nos dados; F usa todos os níveis de um fator.
 - `na.translate`
F remove valores faltantes da escala.
 - `labels`
NULL (nenhum nome **ticks**) ou um vetor com nome (caracteres) dos **ticks**.
`labels = c("One Hundred Fifty", "Three Hundred", "Four Hundred Fifty")`
 - `limits`
Vetor de caracteres, ou números, com os possíveis limites dos valores de escala e sua ordem.
`limits = c("caracter_1", "caracter_2")`
`limits = c(0, 600)`
 - `name`
Nome da escala que aparece na legenda (rótulos de x).
 - `breaks`
O argumento **breaks** nos permite especificar onde os **ticks** aparecem.
Podemos dar nomes aos **ticks** especificados para aparecerem, usando o argumento **labels**.
`breaks = c(150, 300, 450),`
`labels = c("One Hundred Fifty", "Three Hundred", "Four Hundred Fifty")`
 - `position`
Posição da escala no eixo x (*top* ou *bottom*) e no eixo y (*left* ou *right*).
`position = 'top'`
 - Exemplo:

```
#Plotando gráfico
p = ggplot(data = Turismo, aes(x=Estado, y=cheg_2012))
p+
geom_blank()+
labs(title = "Título",
      x = "Eixo x",
      y = "Eixo y",
      subtitle = "Subtítulo",
      caption = "Elaborado por ...")+
theme_bw(base_size = 18)+ #Tema
scale_x_discrete(limits=c("Amazonas", "RioJaneiro"))
#Vetor de caracteres com os possíveis valores de escala e sua ordem.
```

11 Andamento dos Estudos

11.1 Assunto em andamento:

Atualmente estou estudando Cap.7, gráficos com **ggplot2**.

Referências

ALCOFORADO, L. F. **UTILIZANDO A LINGUAGEM R: conceitos, manipulação, visualização, modelagem e elaboração de relatórios**. Rio de Janeiro: Departamento de estatística da UFF; Alta Books Editora, 2021.